

Analyse und Prognose von Aktienkursen/-indizes: Vergleich und Bewertung von Methoden aus dem Bereich Zeitreihenprognose

Pascal Wagener (1207905), Yann Chevalaz (1659827)

01.08.2023



Modul: Projektseminar Business Analytics

Sommersemester 2023

Inhaltsverzeichnis

1	Einleitung	1
2	Einführung und grundlegende Konzepte	2
2.1	Zeitreihen	2
2.2	Stationarität	2
2.3	Aktienmarkt und Indizes	4
3	Zeitreihenanalyse und -Prognose	4
3.1	Zeitreihenanalyse	4
3.2	Zeitreihenprognose	5
4	Prognosemethoden	8
4.1	Holt-Winters	8
4.2	ARIMA	9
4.3	LSTM	10
4.3.1	RNN	10
4.3.2	LSTM-Zelle	11
4.3.3	Normalisierung und Windowing	12
5	Analyseverfahren	14
5.1	Performance-Metriken	15
5.2	Analyseverfahren für Holt-Winters und ARIMA	16
5.3	Analyseverfahren für LSTM-Methoden	17
6	Ergebnisse	18
6.1	Holt-Winters	18
6.2	ARIMA	20
6.3	LSTM	22
6.3.1	LSTM (1. Variante)	24
6.3.2	LSTM-One-Shot (2. Variante)	26
6.4	Methodenvergleich	28
6.4.1	Vergleich der Prognoseverfahren	28
6.4.2	Holt-Winters vs. LSTM (1. Variante)	30
6.4.3	LSTM vs. LSTM-One-Shot	31
7	Dashboard	32
8	Fazit und Ausblick	33
	Literatur	35
	Anhang	37

Abbildungsverzeichnis

1	Zeitreihe vor Differenzierung	3
2	Zeitreihe nach Differenzierung	3
3	BIP von Deutschland (quartalsweise) mit Prognose anhand des Trends	5
4	Durchschnittstemperatur auf Sylt mit Prognose anhand der Saisonalität	6
5	Häufig verwendete Verfahren zur Prognose von Aktien	8
6	Funktionsweise RNN	10
7	Funktionsweise LSTM-Zelle	11
8	Anwendung der Windowing-Technik am Beispiel	14
9	Beispielhafte Aufteilung in Trainings- und Testdaten (Holt-Winters/ARIMA)	16
10	Beispielhafte Aufteilung in Trainings-, Validierungs- und Testdaten (LSTM)	17
11	Vergleich Holt-Winters-Prognose zu tatsächlichen Kursen	20
12	Vergleich ARIMA-Prognose zu tatsächlichen Kursen	21
13	Unterschiedliche LSTM-Prognosen	22
14	Vergleich LSTM-Prognose zu tatsächlichen Kursen	26
15	Vergleich LSTM-One-Shot-Prognose zu tatsächlichen Kursen	28
16	Vergleich Prognose Holt-Winters vs. LSTM	30
17	Vergleich tatsächliche zu angepasste Daten (Holt-Winters)	37
18	Vergleich tatsächliche zu prognostizierte Daten (LSTM)	37
19	Übersicht-Seite Dashboard	38
20	Analyse-Seite 1/2	38
21	Analyse-Seite 2/2	39
22	Prognose-Seite 1/3	39
23	Prognose-Seite 2/3	40
24	Prognose-Seite 3/3	40

Tabellenverzeichnis

1	Auszug der Ergebnisse des Parametertunings von Holt-Winters	19
2	Ergebnisse Zeithorizont Holt-Winters	19
3	Ergebnisse Zeithorizont ARIMA	21
4	Performance vorher vs. nachher	23
5	Ergebnisse der verschiedenen LSTM-Architekturen	25
6	Ergebnisse der verschiedenen Fenstergrößen (LSTM)	25
7	Ergebnisse Zeithorizont LSTM	25
8	Ergebnisse der verschiedenen LSTM-One-Shot-Architekturen	27
9	Ergebnisse der verschiedenen Fenstergrößen (LSTM-One-Shot)	27
10	Ergebnisse Zeithorizont LSTM-One-Shot	27
11	Prognosegüte der verschiedenen Methoden im Vergleich	29
12	Vergleich 30-Tage-Prognose der LSTM-Modelle anhand der Deutschen Post AG .	31

Abkürzungsverzeichnis

AR Auto-Regressiv 6

ARIMA Auto-Regressive Integrated Moving-Average 7

CNN Convolutional Neural Network 7

LSTM Long Short Term Memory 7

MA Moving-Average 6

MAE Mean Absolute Error 15

MSE Mean Squared Error 15

NN Neuronales Netz 7

RMSE Rooted Mean Squared Error 15

RNN Rekurrentes neuronales Netz 7

1 Einleitung

Das Prognostizieren von wirtschaftlichen Kennzahlen stellt eine der wichtigsten Herausforderungen im aktuellen Forschungsstand der Wirtschafts- und Finanzwissenschaften dar. Der Bereich der Finanzprognosen ist gekennzeichnet durch Datenintensität, Rauschen, Nicht-Stationarität und Unstrukturiertheit, somit ist die Vorhersage von finanziellen Werten eine durchweg komplexe Angelegenheit [7]. Zukunftsbezogene Entscheidungen werden alltäglich getätigt, diese Entscheidungen hängen stark von Erwartungen ab, welche es so präzise wie möglich zu gestalten gehört. Trotz des früheren schlechten Rufes von Prognosen, insbesondere über langfristigen makroökonomischen Kennzahlen, wurden zahlreiche Prognosemethoden entwickelt, welche auch für die Vorhersage von wirtschaftlichen Kennzahlen benutzt werden [3]. In Zeiten zunehmender Volatilität und Unsicherheit auf den Finanzmärkten gewinnen Analyse und Prognose von Aktienkursen stark an Relevanz. Ohne zu behaupten, in einer Glaskugel lesen zu können, ermöglichen diese Methoden aus den Bereichen Statistik und maschinelles Lernen eine Schätzung zukünftiger Daten basierend auf vergangenen Daten. Wichtig ist jedoch zu beachten, dass es derzeit nicht möglich ist, die Zukunft in irgendeiner Form akkurat vorherzusagen. Insbesondere Aktienkurse, welche es in dieser Arbeit zu prognostizieren gilt, unterliegen starken Schwankungen, die teilweise auf unberechenbare Phänomene zurückzuführen sind. Viel mehr als Glaskugelleserei handelt es sich hier darum Methoden zu präsentieren und anzuwenden, welche den geringstmöglichen Abstand zwischen dem Prognosekurs und dem realen Kurs von Aktien darstellen. Ziel ist es außerdem, die Prognose von Aktien in Form eines aussagekräftigen Dashboards darzustellen, welches einem Benutzer einen schnellen Überblick über Aktienkursentwicklungen geben kann.

Zu Beginn der Ausarbeitung werden in Kapitel 2 einführend grundlegende Konzepte zu Zeitreihen und zum Aktienmarkt präsentiert. Im Anschluss daran widmet sich Kapitel 3 der detaillierten Untersuchung der Zeitreihenanalyse und Zeitreihenprognose. Gewisse Methoden zur Prognose von Zeitreihen, welche aufgrund ihrer Relevanz in der Literatur im Rahmen dieser Arbeit ausgewählt wurden, werden in Kapitel 4 beschrieben. Dabei wird insbesondere auf die Funktionsweise dieser Methoden eingegangen. Zusätzlich werden Performance-Metriken und Analyseverfahren in Kapitel 5 dargestellt. Die Ergebnisse dieser Analysen sollen dazu dienen, die besten Einstellungen für die jeweiligen Prognosemethoden zu ermitteln, um die Methoden bestmöglich zu nutzen. Daraufhin werden in Abschnitt 6 die untersuchten Methoden miteinander verglichen. Anschließend wird in Abschnitt 7 das Verfahren zur Erstellung des Dashboards präsentiert. Die Konstruktion des Dashboards und weitere Elemente zur Visualisierung der Analysen und Prognosen werden in Kapitel 7 präsentiert. Den Abschluss stellt Kapitel 8 mit einem Fazit und Ausblick dar.

Diese Ausarbeitung untersucht die Herausforderungen und potenziellen Chancen der Prognose von Aktienkursen. Die Kombination von technischer Analyse, verschiedener Prognoseverfahren und visueller Darstellungen innerhalb eines Dashboards bietet eine leistungsstarke Anwendung zur Informationsgewinnung und ermöglicht eine effektive Nutzung von Prognosedaten.

2 Einführung und grundlegende Konzepte

In diesem Abschnitt werden theoretische Grundlagen aus den Gebieten der Zeitreihenanalyse- und Prognose hervorgehoben. Zuerst wird der Begriff Zeitreihe in Kapitel 2.1 definiert, woraufhin auf die Stationarität einer Zeitreihe eingegangen wird. Zum Schluss des Kapitels wird sowohl der Aktienmarkt als auch Indizes beschrieben.

2.1 Zeitreihen

Eine Zeitreihe wird als geordnete Menge von Beobachtungen x_t einer Zufallsvariablen X_t definiert, wobei der Zeitindex $t \in \mathcal{T}$ die zeitliche Ordnung der Beobachtungen repräsentiert [12]. Wenn bspw. die Anzahl an Vögeln an einem bestimmten Ort beobachtet und als Zeitreihe dargestellt wird, impliziert dies, dass die beobachteten Werte der Variable “Anzahl der Vögel“ zeitlichen Schwankungen unterliegen, da sie sich im Laufe der Zeit verändern. Des Weiteren kann die Variable als eine Zufallsvariable betrachtet werden, da sie gewissen zufälligen Einflüssen unterliegt [12]. Eine zusätzliche Eigenschaft von Zeitreihen ist die Äquidistanz der Beobachtungen. Dies bedeutet, dass der zeitliche Abstand zwischen den Beobachtungen konstant sein muss, um eine gültige Zeitreihe zu bilden. Im konkreten Beispiel der Vögel-Zählung müsste das Zeitintervall, in dem die Anzahl der Vögel gezählt wird, immer gleich sein (z. B. eine Zählung pro Stunde), um die Anforderungen einer Zeitreihe zu erfüllen.

2.2 Stationarität

Um Zeitreihen sinnvoll analysieren zu können, muss Stationarität sichergestellt werden. Ein stochastischer Prozess wird als stationär betrachtet, wenn seine statistischen Eigenschaften sich im Verlauf der Zeit nicht ändern. Insbesondere ist zu betrachten, dass der Erwartungswert konstant bleibt, die Varianz endlich ist, und die Autokovarianz nicht von der Verschiebung abhängt [16]. Um festzustellen, ob eine Zeitreihe stationär ist, können verschiedene statistische Tests angewendet werden, wie bspw. der Kwiatkowski–Phillips–Schmidt–Shin-Test. Falls die Stationarität nicht gegeben ist, muss die Zeitreihe möglicherweise durch Differenzierung stationarisiert werden. Differenzierung ist ein Verfahren, welches durch Subtraktion des aktuellen Werts von dem vorherigen Wert in der Zeitreihe die Differenzen zwischen aufeinanderfolgenden Werten berechnet. Abbildung 1 zeigt den Verlauf einer Zeitreihe vor der Anwendung der Differenzierung. Der p-Wert, auch Signifikanzwert genannt, ist ein Maß für die Glaubwürdigkeit der Nullhypothese. In diesem Kontext wurde ein p-Wert ≤ 0.05 festgestellt, was die Nullhypothese verwirft und somit darauf hindeutet, dass die Zeitreihe nicht stationär ist.




Abbildung 1: Zeitreihe vor Differenzierung

Abbildung 2 zeigt den Verlauf derselben Zeitreihe, nachdem Differenzierung angewandt wurde. In diesem Falle ist zu beachten, dass der p-Wert ≥ 0.05 ist, hierdurch kann man schließen, dass in dieser Zeitreihe Stationarität vorliegt [23].

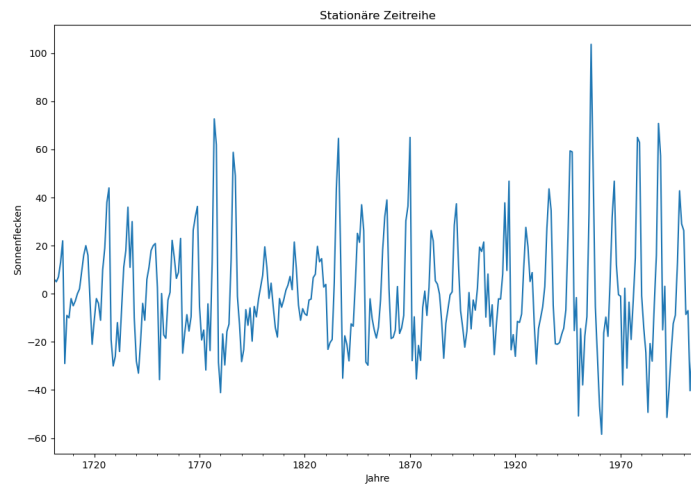


Abbildung 2: Zeitreihe nach Differenzierung

2.3 Aktienmarkt und Indizes

In diesem Abschnitt werden der Aktienmarkt und Aktienindizes vorgestellt. Eine Aktie repräsentiert einen Anteil des Grundkapitals eines Unternehmens [15]. Der Preis einer Aktie ist schwankend, da er von Angebot und Nachfrage abhängt. Sobald eine Aktie mehr gekauft als verkauft wird, steigt der Aktienkurs, und sobald mehr verkauft als gekauft wird, sinkt der Kurs. Externe und zufällige Faktoren können starken Einfluss sowohl auf Angebot als auch auf Nachfrage haben, und somit die Schwankungen im Aktienkurs beeinflussen. Der Aktienmarkt kann als eine Momentaufnahme der zukünftigen Wachstumserwartungen von Unternehmen und der Wirtschaft im Allgemeinen betrachtet werden [6]. Es ist wichtig zu beachten, dass der Aktienmarkt nichtlinear, nicht stationär und chaotisch ist [20]. Es existieren zwei hauptsächliche Methoden der Aktienmarktanalyse, einerseits die fundamentale Analyse, welche sich mit makroökonomischen, industriellen und unternehmensspezifischen Analysen beschäftigt, und andererseits die technische Analyse, welche Datenkurse anhand statistischer Merkmale analysiert.

Ein Aktienindex ermöglicht die Analyse mehrerer Kursverläufe gleichzeitig durch die Berechnung eines nach Kapitalisierung gewichteten Durchschnitts. Indizes können einen ganzen Markt zusammenfassen, oder aber auch nur gewisse Sektoren oder Länder. Oft dienen Indizes auch als Benchmarks. Wenn die Performance einer Aktie tendenziell besser ist als die des ausgewählten Index, wird die Aktie positiv bewertet.

Da der Wert einer Aktie häufig als Zeitreihe betrachtet wird, ist die Zeitreihenanalyse von besonderer Bedeutung für die Vorhersage von Aktienkursen [22]. In Bezug auf den Aktienmarkt ermöglicht die Zeitreihenanalyse die Identifizierung von Trends, Mustern, saisonalen Effekten und anderen wiederkehrenden Verhaltensweisen, die für die Vorhersage von zukünftigen Kurschwankungen und Risikobewertungen von Aktien und Aktienindizes von Relevanz sein können.

3 Zeitreihenanalyse und -Prognose

In diesem Kapitel werden die Begriffe Zeitreihenanalyse und -Prognose definiert und erläutert. Hierbei liegt besondere Beachtung auf den grundlegenden Konzepten und Methoden der Zeitreihenprognose.

3.1 Zeitreihenanalyse

Ziel der Zeitreihenanalyse ist es, das Verhalten verschiedener Komponenten welche in einer Zeitreihe (zum Zeitpunkt t) enthalten sind, zu ermitteln. Die erste zu betrachtende Komponente ist die glatte Trendkomponente T_t , welche die Grundrichtung der Zeitreihe angibt (aufsteigend, absteigend, konstant). Die zweite Komponente ist das irreguläre Rauschen E_t , welche den Einfluss von Störfaktoren repräsentiert. Die dritte Komponente ist die Saisonalität S_t , die regelmäßige Schwankungen mit bestimmten Zeitintervallen darstellt, während die vierte Kom-

ponente der Zyklus K_t ist, der regelmäßige, aber nicht genau zeitlich festgelegte Schwankungen abbildet.

Sobald diese Komponenten ermittelt sind, können sie isoliert oder eliminiert werden. Hierzu gibt es zwei hauptsächliche Modelle, einerseits das additive Modell und andererseits das multiplikative Modell. Im additiven Modell $T_t + S_t + K_t + E_t$ überlagern sich die Komponenten, die Elimination erfolgt durch Subtraktion. Im multiplikativen Modell $T_t \cdot S_t \cdot K_t \cdot E_t$ verstärken sich die Komponenten gegenseitig, die Elimination erfolgt durch Division [12].

3.2 Zeitreihenprognose

Die Zeitreihenprognose beschäftigt sich mit der Vorhersage zukünftiger Zeitreihenwerte. Hierzu existieren verschiedene Ansätze. Dieser Abschnitt beabsichtigt jedoch nicht, eine umfassende Übersicht aller Methoden aufzuführen, sondern Grundkonzepte der Zeitreihenprognose darzustellen.

Eine Möglichkeit, um weitere Zeitreihenwerte vorherzusagen, besteht darin, den ermittelten Trend zur Vorhersage zukünftiger Werte zu benutzen. Abbildung 3 zeigt als Beispiel-Zeitreihe das quartalsweise BIP von Deutschland. Der Visualisierung ist zu entnehmen, dass ein steigender Trend vorliegt. Eine einfache Prognose anhand des Trends würde zukünftige Zeitreihenwerte dem Trend entsprechend vorhersagen (s. rote Linie).

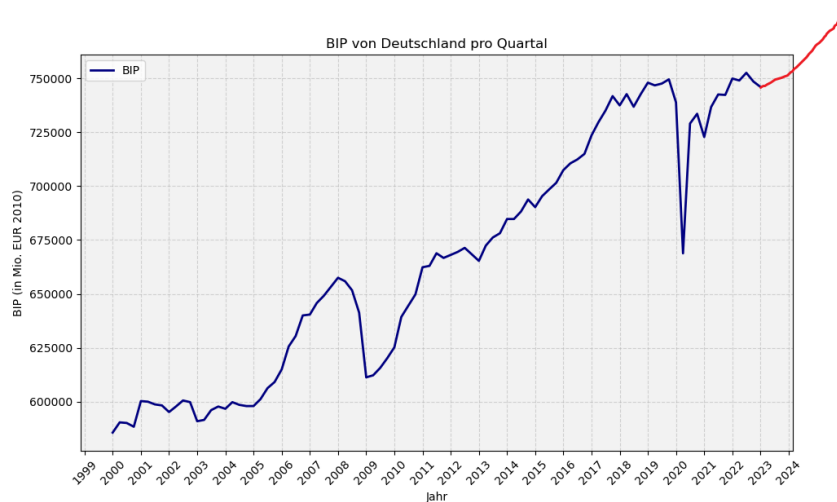


Abbildung 3: BIP von Deutschland (quartalsweise) mit Prognose anhand des Trends

Eine weitere Alternative um Zeitreihenwerte vorherzusagen ist die ermittelte Saisonalität zur Vorhersage zukünftiger Werte zu benutzen. Abbildung 4 zeigt als Beispiel-Zeitreihe die Durchschnittstemperatur auf Sylt innerhalb von zwei Jahren. Hier kann erkannt werden, dass die Tem-

peratur einem klaren saisonalen Verlauf folgt. Eine einfache Prognose anhand der Saisonalität würde zukünftige Zeitreihenwerte der Saisonalität entsprechend vorhersagen (s. rote Linie).




Abbildung 4: Durchschnittstemperatur auf Sylt mit Prognose anhand der Saisonalität

Die Grundlage vieler statistischer Prognosemethoden sind sogenannte Auto-Regressive (AR) Prozesse. Ein AR-Modell beschreibt eine lineare Beziehung zwischen einem Zeitreihenwert aus der Periode $t + 1$ und dem Wert aus der vorherigen Periode t . Dies bedeutet, dass die zukünftige Entwicklung der Zeitreihe durch die Vergangenheit beeinflusst wird und die Prognose auf den vergangenen Werten basiert [3]. Mathematisch lässt sich ein AR-Modell als folgende Gleichung darstellen:

$$\hat{Y}_{t+1} = \beta_0 + \beta_1 Y_t + E_t \quad (1)$$

Dabei stellt Y_t den tatsächlichen Kurs in Periode t , \hat{Y}_{t+1} den Prognosewert, β_0 den Drift, und E_t das Rauschen dar. Im Falle von Gleichung 1 handelt es sich um ein AR-Modell erster Ordnung, hier wird nur ein Vergangenheitswert der zu erklärenden Variable berücksichtigt. Die Anzahl an zu betrachtenden Vergangenheitswerten gilt es anhand von Informationskriterien zu ermitteln. In diesem Modell wird die Vorhersage des nächsten Werts durch die lineare Kombination des vorherigen Werts Y_t und des Fehlerterms E_t gebildet. Die Koeffizienten β geben an, wie stark der vorherige Wert Y_t gewichtet wird. Ein positiver Koeffizient β bedeutet, dass ein hoher vorheriger Wert zu einer hohen Vorhersage führt, ein negatives β genau umgekehrt.

Zusätzlich zu den AR-Modellen werden auch häufig Moving-Average (MA) Prozesse verwendet, um eine Prognose aus Vergangenheitswerten abzuleiten. Bei MA-Verfahren wird der Prognosewert durch den Mittelwert der k letzten Werte berechnet:

$$\hat{Y}_{t+1} = \frac{1}{k} \sum_{i=t-k+1}^t Y_i \quad (2)$$

Gleichung 2 stellt einen einfachen MA-Prozess dar. Ein Sonderfall eines MA-Prozesses ist die exponentielle Glättung. Dieses Verfahren wurde von Holt entwickelt und beruht darauf, nicht nur den einfachen Durchschnitt wie bei herkömmlichen MA-Prozessen zu berechnen, sondern einen gewichteten Durchschnitt, bei dem die Gewichte mit der Vergangenheit exponentiell abnehmen [3]. Dies ist in Gleichung 3 dargestellt:

$$\hat{Y}_{t+1} = \alpha \cdot Y_t + (1 - \alpha) \cdot \hat{Y}_t \quad (3)$$

Dabei ist $0 < \alpha < 1$ der Glättungsfaktor und \hat{Y}_t der geglättete Wert. Der Glättungsfaktor bestimmt, ob Werte, welche weiter in der Vergangenheit liegen, stärker gewichtet werden als aktuellere Werte. Wenn der Glättungsfaktor bei 1 liegt, bedeutet dies, dass der tatsächliche Wert Y_t stärker gewichtet wird als der geglättete Wert.

In diesem Abschnitt wurden grundlegende Konzepte der Zeitreihenanalyse und Zeitreihenprognose erläutert, die als fundamentale Bausteine für die in Kapitel 4 vorgestellten Prognosemethoden dienen. In der Prognose von Zeitreihenwerten, insbesondere in der Aktienmarktanalyse, gibt es eine Vielzahl von Ansätzen, die über die bisher erwähnten statistischen Methoden hinausgehen. Abbildung 5 zeigt eine Taxonomie der Ansätze zur Aktienmarktprognose, die auf Shah's Taxonomie basiert [20]. Diese Darstellung verdeutlicht, dass neben statistischen Methoden, wie bspw. das in Kapitel 4.2 vorgestellte Auto-Regressive Integrated Moving-Average (ARIMA) Verfahren, auch andere Ansätze existieren. Ein solcher Ansatz ist die Mustererkennung mit Perceptually Important Points (PIP) Verfahren, bei dem nur die signifikantesten Datenpunkte beibehalten werden, um die Dimension der Zeitreihe zu reduzieren. PIP-Verfahren konzentrieren sich auf die Erkennung und Extraktion wichtiger Muster und Ereignisse in der Zeitreihe, die für die Vorhersage von Bedeutung sein können. Ein weiterer Ansatz ist die Sentimentanalyse, bei der Texte aus Nachrichten und sozialen Medien analysiert werden, um Stimmungen und Meinungen zu erfassen, die den Aktienmarkt beeinflussen könnten.

Außerdem werden auch Verfahren, die auf das maschinelle Lernen basieren, häufig verwendet, um Aktienkurse vorherzusagen. Hier sollen insbesondere neuronale Netze (NN) von Relevanz sein. Davon werden hauptsächlich rekurrente neuronale Netze (RNN), Convolutional Neural Networks (CNN) und Long Short Term Memory (LSTM) zur Aktienprognose genutzt. CNN bestehen ähnlich wie traditionelle NN aus mehreren Neuronen, die durch eine hierarchische Struktur miteinander verbunden sind. Dabei können die Gewichte und Verzerrungen zwischen den Schichten trainiert werden, um eine lernfähige Architektur zu erreichen [6]. RNN und LSTM werden in Kapitel 4.3 näher erläutert. Neben den NN sind auch Support Vector Machines (wie in [7] beschrieben) und Random Forest (wie in [20] erwähnt) relevante Methoden.

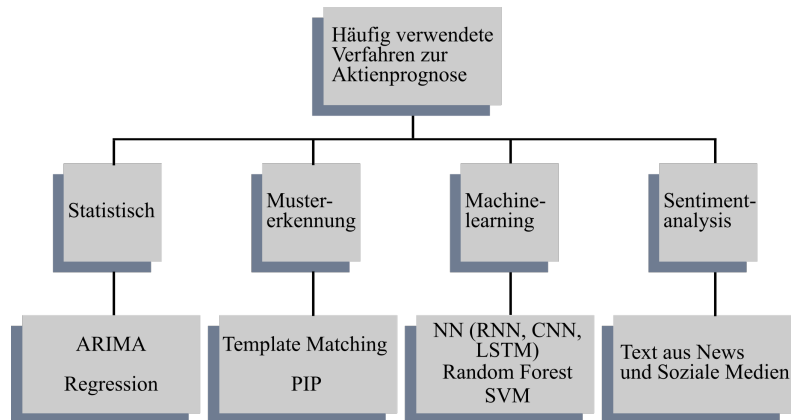


Abbildung 5: Häufig verwendete Verfahren zur Prognose von Aktien

4 Prognosemethoden

In diesem Kapitel werden drei verschiedene Prognosemethoden (Holt-Winters, ARIMA, LSTM) vorgestellt, welche im Rahmen dieser Ausarbeitung praktisch angewendet werden. Hier gilt es zuerst diese Methoden aus einem theoretischen Standpunkt zu erklären.

4.1 Holt-Winters

Die Holt-Winters-Methode wurde ursprünglich 1960 von Winters entwickelt und ist ein zeitreihenbasiertes Prognoseverfahren, welches zur Vorhersage von zukünftigen Werten in einer Zeitreihe verwendet wird. Es handelt sich hierbei um ein statistisches Prognoseverfahren und ist nützlich für saisonale Daten, bei denen Muster und Trends wiederkehren. Außerdem stellt es eine Erweiterung der klassischen exponentiellen Glättung dar. Da die klassische exponentielle Glättung weder Trends noch Saisonalität vorhersagen kann, fügt die Methode von Holt-Winters der exponentiellen Glättung Trend- und Saisonkomponenten hinzu [5]. Die drei Komponenten Niveau, Trend und saisonaler Verlauf werden durch exponentielle Glättung berechnet. Mit $0 \leq \alpha, \beta, \delta < 1$, und p als Anzahl Zeitintervalle in einer Saison, verläuft die Berechnung der drei Komponenten wie in den Gleichungen 4-6. Dabei stellen α , β , und δ Gewichtungsfaktoren dar, die den Einfluss der aktuellen und älteren Werte auf die zu berechnende Komponente steuert [26]. So führt bspw. ein hoher α -Wert zu einer stärkeren Anpassung an die aktuelle Beobachtung. Dabei hat die Wahl dieser Parameter enormen Einfluss auf die Performance der Methode. Die Gewichtungsfaktoren werden meistens mithilfe von Heuristiken geschätzt oder im Voraus festgelegt. Zur Bestimmung der Initialwerte für die drei Komponenten existieren verschiedene Vorgehensweisen, die in dieser Ausarbeitung nicht weiter erläutert werden, aber bspw. in Rahman et al. [19] nachgeschlagen werden können.

$$\text{Niveau} : L_n = \alpha \cdot \frac{\gamma_n}{S_{n-p}} + (1 - \alpha) \cdot (L_{n-1} + T_{n-1}) \quad (4)$$

$$\text{Trend} : T_n = \beta \cdot (L_n - L_{n-1}) + (1 - \beta) \cdot T_{n-1} \quad (5)$$

$$\text{Saison} : S_n = \delta \cdot \frac{\gamma_n}{L_n} + (1 - \delta) \cdot S_{n-p} \quad (6)$$

Die Berechnung der Vorhersage für den Horizont h kann nach zwei unterschiedlichen Methoden erfolgen, einerseits die additive Methode und andererseits die multiplikative Methode. Nach der additiven Methode bildet sich die Vorhersage wie in Gleichung 7 beschrieben. Wird die multiplikative Methode gewählt, so berechnet sich die Vorhersage für den Horizont h wie in Gleichung 8.

$$F_{n+h} = L_n + h \cdot T_n + S_{n+h-p} \quad (7)$$

$$F_{n+h} = (L_n + h \cdot T_n) \cdot S_{n+h-p} \quad (8)$$

4.2 ARIMA

Bei der ARIMA-Methode handelt es sich ebenfalls um ein statistisches Modell zur Zeitreihenanalyse und -prognose. Dabei besteht es aus einer Kombination des AR- und MA-Verfahren. ARIMA-Modelle unterstellen, dass eine Zeitreihe stationär ist. Um dies zu erreichen, integriert (Integrated, I) ARIMA eine Methode zur Beseitigung von Verzerrungen, die durch Trends hervorgerufen werden. Der Parameter d gibt an, wie oft man differenzieren muss, damit die Zeitreihe stationär wird [3]. Gleichung 9 beschreibt ein ARIMA(p,d,q)-Modell, wobei X_t die Zeitreihendaten, $\phi_{p(B)}$ den AR-Polynomteil, $\theta_{q(B)}$ den MA-Polynomteil, B den Backshift-Operator, p die Ordnung der AR-Komponente, d den Differenzierungsgrad, q die Ordnung der MA-Komponente und E_t das Rauschen repräsentieren [1].

$$ARIMA(p, d, q) : \phi_p(B)(1 - B)^d X_t = \theta_q(B)E_t \quad (9)$$

Die Bestimmung der Parameter p , d und q erfolgt durch statistische Methoden wie (partielle) Autokorrelationsdiagramme. Das beste Modell wird mithilfe eines gewissen Informationskriterium ermitteln. Häufig werden hierfür das Akaike-Information-Kriterium oder das Bayesian-Information-Kriterium verwendet.

Es ist jedoch zu beachten, dass eine wichtige Grenze von ARIMA-Methoden darin liegt, dass diese hauptsächlich für Zeitreihen geeignet sind, welche lineare Zusammenhänge darstellen. Sobald eine Zeitreihe nichtlinear ist, wie z. B. bei komplexeren Aktienkursverläufen, eignen sich eher Methode aus dem Bereich des maschinellen Lernens wie bspw. LSTM-Methoden, welche in dem folgenden Teil 4.3 erläutert werden.

4.3 LSTM

In Folgenden werden detaillierte Ausführungen zur LSTM-Methode vorgenommen. Da diese eine Erweiterung von RNN darstellt, wird zuvor eine kurze Einführung in letztere gegeben. Nachdem die Grundlagen der LSTM-Modelle erläutert sind, werden zwei Techniken zur Datenaufbereitung beschrieben, welche vor Anwendung des LSTM einzusetzen sind.

4.3.1 RNN

Deep Learning ist ein Fachgebiet des maschinellen Lernens, dessen Schwerpunkt auf dem Training künstlicher NN mit mehreren versteckten Schichten liegt, um automatischen Datendarstellungen zu erlernen [2]. Die sogenannten tiefen NN haben in verschiedenen Bereichen wie bspw. der Spracherkennung große Erfolge erzielt. Sie sind in der Lage, komplexe Muster aus großen Datenmengen innerhalb kurzer Zeit zu erlernen. Eine spezielle Form der tiefen NN sind die sogenannten RNN, die darauf ausgerichtet sind, sequenzielle Daten zu verarbeiten [14]. Der wesentliche Unterschied eines RNN liegt in der Einführung von Schleifen innerhalb seiner Architektur, wodurch Informationen aus früheren Eingaben beibehalten und für nachfolgende Schritte genutzt werden können [13]. Dadurch eignen sich RNN besonders gut für Aufgaben mit zeitlichen Abhängigkeiten, wie bspw. die Zeitreihenanalyse.

Das zentrale Element eines RNN ist sein verborgener Zustand HL_t (Hidden Layer), der als Art Gedächtnis des Netzwerks dient. Bei jedem Zeitschritt t nimmt das RNN eine Eingabe X_t (Input) und gibt basierend auf dem vorherigen verborgenen Zustand HL_{t-1} und der aktuellen Eingabe X_t eine Ausgabe O_t (Output) aus. Zusätzlich wird der verborgene Zustand aktualisiert, wodurch er wiederum Einfluss auf den Output des nächsten Zeitschrittes hat. Die Funktionsweise ist in Abbildung 6 in einer vereinfachten eingeklappten und ausführlicheren ausgeklappten Fassung dargestellt. RNN verarbeiten also eine Zeitreihe schrittweise und behalten von Zeitschritt zu Zeitschritt einen internen Zustand bei.




Abbildung 6: Funktionsweise RNN

Da aber die Performance der Standard-RNN mit zunehmender Modellkomplexität und der Erfassung von langen Abhängigkeiten abnimmt [14], wurden LSTM-Netze als Erweiterung der RNN entwickelt.

4.3.2 LSTM-Zelle

Die LSTM-Methode wurde im Jahr 1997 von Sepp Hochreiter und Jürgen Schmidhuber vorgestellt und dient als Lösung der Probleme traditioneller RNN [14]. Der grundlegende Ansatz besteht darin, das Netzwerk so zu erweitern, dass es in der Lage ist, Informationen über einen langen Zeitraum hinweg speichern und abrufen zu können. Der zentrale Baustein des LSTM ist die sogenannte LSTM-Zelle, welche aus drei verschiedenen Tor-Mechanismen besteht, die den Datenfluss in und aus einer Zelle steuern [13]. Diese Tore sind das Forget-Gate (Vergessenstor), das Input-Gate (Eingangstor) und das Output-Gate (Ausgangstor).

Im Folgenden wird der Aufbau einer LSTM-Zelle anhand der Beschreibung von Smagulova und James (2019) [21] kurz erläutert. Es sei jedoch angemerkt, dass in der Vergangenheit verschiedene LSTM-Konfigurationen vorgestellt wurden, die unterschiedliche Notationen für die Beschreibung der Zelle verwenden. Daher dient die folgende Darstellung lediglich als Orientierung.

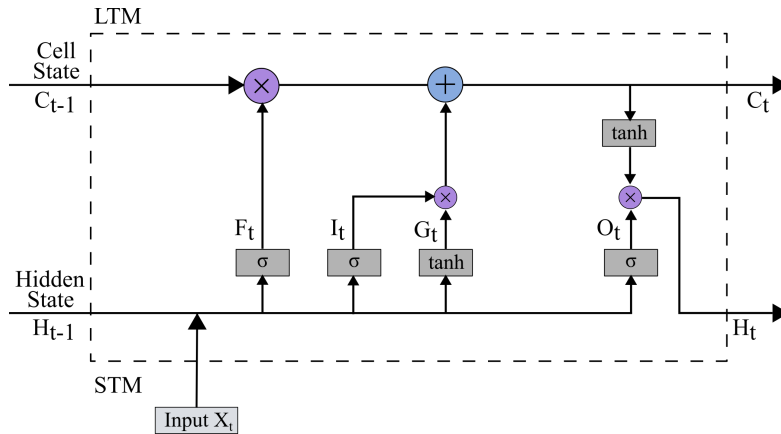


Abbildung 7: Funktionsweise LSTM-Zelle

In Abbildung 7 wird die Struktur einer LSTM-Zelle zum Zeitpunkt t veranschaulicht. Ähnlich zum RNN besitzt sie einen verborgenen Zustand, der sich über die einzelnen Zeitschritte anpasst. Dieser Zustand wird als Hidden-State H_t bezeichnet und fungiert als Kurzzeitgedächtnis (Short Term Memory, STM). Zusätzlich dazu gibt es ein Langzeitgedächtnis (Long Term Memory, LTM), welches als Cell-State C_t definiert wird. In jedem Zeitschritt t nimmt die LSTM-Zelle eine Eingabe X_t entgegen, die zusammen mit dem Hidden-State des vorherigen Zeitschrittes H_{t-1} als Eingabe für die entsprechenden Aktivierungsfunktionen (Sigmoid σ oder \tanh) der Tore verwendet wird. Das Forget-Gate F_t entscheidet, welche Informationen aus H_{t-1} vergessen werden sollen und gibt

diese Informationen an den Cell-State des vorherigen Zeitschrittes C_{t-1} weiter. Das Input-Gate I_t quantifiziert die Wichtigkeit der neuen Information, die durch X_t eingebracht wird. Diese Information wird mit der neuen Information G_t multipliziert und an C_{t-1} weitergegeben. Das Output-Gate O_t bestimmt, welche Informationen aus dem aktuellen Zellzustand als Ausgabe weitergegeben werden sollen. Die Aktualisierung des Cell- und Hidden-State erfolgt mithilfe der Gleichung 10 und 11. Hierbei wird deutlich, dass der Hidden-State eine Funktion des Cell-State und der aktuellen Ausgabe ist. Sollte die Ausgabe des aktuellen Zeitschrittes t bspw. zur Prognose eines nächsten Kurses benötigt werden, so kann die SoftMax-Aktivierungsfunktion auf H_t angewendet werden.

$$C_t = G_t \cdot I_t + F_t \cdot C_{t-1} \quad (10)$$

$$H_t = O_t \cdot \tanh(C_t) \quad (11)$$

Das LSTM-Modell lernt anhand von Gewichten, die zu Beginn des Trainings zufällig initialisiert werden. Im Laufe des Trainings werden diese Gewichte mithilfe verschiedener Verfahren, wie bspw. Backpropagation, angepasst, um die Vorhersagegenauigkeit des Modells zu verbessern. In Abbildung 7 sind die Gewichte nicht explizit dargestellt, aber sie würden sich an den entsprechenden Pfeilen befinden.

Im Vergleich zu traditionellen RNN aktualisiert das LSTM nicht nur seinen versteckten Zustand nach jedem Zeitschritt. Stattdessen kann es dank der speziellen Struktur der LSTM-Zelle Informationen über mehrere Zeitschritte hinweg speichern und auf diese zugreifen. Dadurch ist es in der Lage, Abhängigkeiten und Muster über längere Zeiträume zu erfassen und eignet sich daher gut für die Zeitreihenanalyse- und Prognose.

In dieser Ausarbeitung wurden zwei LSTM-Modelle als Prognoseverfahren entwickelt, die sich in Bezug auf die Anzahl der zu prognostizierenden Tage unterscheiden. Die erste Variante (im Folgenden als LSTM bezeichnet) prognostiziert genau einen Tag in die Zukunft. Für die Prognose des zweiten Tages verwendet sie u.a. den vorhergesagten Wert des ersten Tages. Im Gegensatz dazu prognostiziert die zweite Variante direkt zehn Tage in die Zukunft, ohne bereits prognostizierte Werte zu berücksichtigen. Diese Variante wird daher als LSTM One-Shot bezeichnet. Die beiden Modelle unterscheiden sich also ausschließlich durch ihr spezifisches Trainings auf die Prognose eines einzelnen Tages oder von direkt zehn Tagen.

4.3.3 Normalisierung und Windowing

Bevor die historischen Kurse der Aktien/Indizes als Eingabe in ein LSTM-Modell gegeben werden können, sollten diese zuerst aufbereitet werden. Die Datennormalisierung und die sogenannte Windowing-Technik spielen dabei eine wichtige Rolle. Diese beiden Methoden werden nun kurz,

beginnend mit der Normalisierung, dargestellt.

Die Datennormalisierung ist ein essenzieller Schritt in der Datenaufbereitung für maschinellen Lernens. In den meisten Anwendungsfällen liegen die Wertebereiche verschiedener Attribute in unterschiedlichen Größenordnungen. Gerade bei distanzbasierten Methoden kann es vorkommen, dass die Attribute in größeren Wertebereichen die kleineren dominieren und ihnen somit mehr Gewicht zugeschrieben werden, wodurch relevante Informationen verloren gehen können [4]. Dieser Umstand wird mittels Normalisierung aufgehoben. Dabei werden die Daten in einen bestimmten Wertebereich, typischerweise zwischen 0 und 1, transformiert, um eine einheitliche Skala für die Attribute zu gewährleisten. Obwohl in folgendem Anwendungsfall, in dem nur die Kurswerte als Attribute betrachtet werden, die Normalisierung nicht unbedingt erforderlich ist, hat sich gezeigt, dass neuronale Netze mit normalisierten Daten effizienter arbeiten [9]. In der Praxis sind zwei wesentliche Konzepte zur Normalisierung von Daten bekannt. Zum einen die Min-Max-Methode und zum anderen die Standardisierung. Die Min-Max-Methode wird in dieser Arbeit für die Normalisierung verwendet. Hierbei werden alle Werte linear zwischen 0 und 1 skaliert, wobei der minimale Wert x_{min} auf 0 und der maximale Wert x_{max} auf 1 transformiert wird.

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (12)$$

Die normalisierten Werte ergeben sich dann durch Anwendung von Gleichung 12 auf alle Datenpunkte.

Die zweite erwähnte Methode zur Datenaufbereitung für LSTM-Modelle und weiterer maschineller Lernalgorithmen ist die Windowing-Technik. Hierbei wird die Zeitreihe über Querschnittsdaten zu einem neuen Datensatz umstrukturiert [10]. Die Windowing-Technik unterteilt dazu die Zeitreihe in mehrere überlappende Fenster (Windows). Jedes Fenster besteht aus $m + 1$ aufeinanderfolgenden Werten, wobei die ersten m Werte als Attribute angesehen werden und der $+1$ Wert als zu prognostizierende Zielvariable dient. Somit stellt jedes Fenster einen neuen Datenpunkt im generierten Datensatz dar. Das Fenster wird dann über eine definierte Schrittlänge verschoben, sodass die gesamte Zeitreihe in die verschiedenen Fenster aufgeteilt wird.

Diese Technik ist anhand eines Beispiels in Abbildung 8 verdeutlicht. Dabei beträgt die Fenstergröße $5 + 1$ Kurse und wird jeweils um eine Zeile (Schrittlänge) verschoben. Auf der linken Seite ist der originale Datensatz und auf der rechten Seite, der durch die angewendete Technik erzeugte neue Datensatz, dargestellt. Der linke rote Kasten beinhaltet sechs aufeinanderfolgende Kurse. Der letzte Kurs wird im neuen Datensatz als Zielvariable und dessen Datum als Zieldatum interpretiert. Die vorherigen fünf Kurse werden als Attribute zur Vorhersage der Zielvariable genutzt. Danach wird der Kasten (dann blau) um eine Zeile nach unten verschoben. Dieser Vorgang wiederholt sich bis ans Ende der Zeitreihe.

Die Wahl der Fenstergröße und Schrittlänge kann einen Einfluss auf die Performance des LSTM-Modells haben und sollte sorgfältig abgewogen werden [10]. Im Verlauf dieser Ausarbeitung wird

die Fenstergröße variiert, die Schrittlänge aber konstant bei eins gehalten.

Date	Value (€)	Target Date	Target-5	Target-4	Target-3	Target-2	Target-1	Target
03.01.2023	108.1	10.01.2023	108.1	113.64	110.34	113.06	119.77	118.85
04.01.2023	113.64	11.01.2023	113.64	110.34	113.06	119.77	118.85	123.22
05.01.2023	110.34	12.01.2023	110.34	113.06	119.77	118.85	123.22	123.56
06.01.2023	113.06	13.01.2023	113.06	119.77	118.85	123.22	123.56	122.4
09.01.2023	119.77	17.01.2023	119.77	118.85	123.22	123.56	122.4	131.49
10.01.2023	118.85	18.01.2023	118.85	123.22	123.56	122.4	131.49	128.78
11.01.2023	123.22	19.01.2023	123.22	123.56	122.4	131.49	128.78	127.17
12.01.2023	123.56	20.01.2023	123.56	122.4	131.49	128.78	127.17	133.42
13.01.2023	122.4	23.01.2023	122.4	131.49	128.78	127.17	133.42	143.75
17.01.2023	131.49	24.01.2023	131.49	128.78	127.17	133.42	143.75	143.89
18.01.2023	128.78	25.01.2023	128.78	127.17	133.42	143.75	143.89	144.43
19.01.2023	127.17	26.01.2023	127.17	133.42	143.75	143.89	144.43	160.27
20.01.2023	133.42	27.01.2023	133.42	143.75	143.89	144.43	160.27	177.9
23.01.2023	143.75	30.01.2023	143.75	143.89	144.43	160.27	177.9	166.66
24.01.2023	143.89	31.01.2023	143.89	144.43	160.27	177.9	166.66	173.22
25.01.2023	144.43	01.02.2023	144.43	160.27	177.9	166.66	173.22	181.41
26.01.2023	160.27	02.02.2023	160.27	177.9	166.66	173.22	181.41	188.27
27.01.2023	177.9	03.02.2023	177.9	166.66	173.22	181.41	188.27	189.98
30.01.2023	166.66	06.02.2023	166.66	173.22	181.41	188.27	189.98	194.76
31.01.2023	173.22	07.02.2023	173.22	181.41	188.27	189.98	194.76	196.81
01.02.2023	181.41	08.02.2023	181.41	188.27	189.98	194.76	196.81	201.29
02.02.2023	188.27	09.02.2023	188.27	189.98	194.76	196.81	201.29	207.32
03.02.2023	189.98	10.02.2023	189.98	194.76	196.81	201.29	207.32	196.89
06.02.2023	194.76							
07.02.2023	196.81							
08.02.2023	201.29							
09.02.2023	207.32							
10.02.2023	196.89							

Abbildung 8: Anwendung der Windowing-Technik am Beispiel

Nachdem der Datensatz umstrukturiert wurde, kann dieser fürs LSTM genutzt werden. Dabei enthält ein Input nun mehrere vergangene, aufeinanderfolgende Kurse, die zur Prognose eines (bzw. zehn bei LSTM-One-Shot) nächsten Kurses verwendet werden. Dadurch können vergangene Informationen und Muster effizient genutzt werden, um genauere Vorhersagen treffen zu können.

Durch die Kombination der Datennormalisierung und der Windowing-Technik können die historischen Kursdaten optimal in das LSTM-Modell eingegeben werden, um möglichst präzise Vorhersagen für die zukünftigen Kurse zu erzielen.

5 Analyseverfahren

Zur Evaluierung der in Kapitel 4 vorgestellten Prognosemethoden wurden verschiedene Analyseverfahren entwickelt. Aufgrund der Unterschiede zwischen den statistischen Methoden und den LSTM-Verfahren hinsichtlich der Datenaufteilung in verschiedene Sets, werden die Analyseverfahren getrennt voneinander beschrieben, obwohl sie gemeinsame Elemente aufweisen. Zunächst werden die verwendeten Performance-Metriken erläutert, bevor die Analyseverfahren dargestellt werden.

5.1 Performance-Metriken

Performance-Metriken sind Kennzahlen, die dazu dienen, die Leistung von Modellen oder Vorhersagen in unterschiedlichen Anwendungsgebieten zu bewerten. Sie erlauben eine objektive Beurteilung der Qualität und Genauigkeit von Modellen [27]. Diese Messwerte spielen eine bedeutende Rolle in vielen Bereichen des maschinellen Lernens oder der Datenanalyse. Sie werden häufig genutzt, um die Vorhersagegenauigkeit von Modellen zur Zeitreihenprognose zu messen [8]. Oft genutzte Kennzahlen sind der durchschnittliche absolute Fehler (MAE) und der quadratische durchschnittliche Fehler (MSE), bzw. die Wurzel des mittleren quadratischen Fehlers (RMSE). Sowohl der MAE, als auch der RMSE sind absolute Fehlerkennzahlen, die verhindern, dass sich positive und negative Abweichungen gegenseitig neutralisieren.

Der MAE misst den durchschnittlichen absoluten Unterschied zwischen den vorhergesagten \hat{y}_i und tatsächlichen y_i Werten. Er ist im Vergleich zum RMSE weniger empfindlich gegenüber Ausreißern. Der MAE ist eine greifbare Kennzahl, da er die durchschnittliche Fehlergröße angibt.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (13)$$

Der RMSE ist eine Erweiterung des MAE und berechnet die quadratische durchschnittliche Abweichung, woraus die Wurzel gezogen wird. Dabei werden größere Abweichungen durch das Quadrieren stärker bestraft.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (14)$$

Im weiteren Verlauf werden die Kennzahlen anhand verschiedener Aktien mit unterschiedlichen Wertebereichen berechnet und anschließend gemittelt. Um eine vergleichbare Bewertung zu gewährleisten, wird die Abweichung prozentual zum Aktienkurs skaliert. Somit wird sichergestellt, dass eine Abweichung von bspw. 5 € bei einer Aktie mit einem Kurs von 200 € nicht mit einer Abweichung von 5 € bei einer Aktie mit einem Kurs von 20 € gleichgesetzt wird. Die errechneten Kennzahlen werden durch den Mittelwert der tatsächlichen Aktienkurse dividiert und mit 100 multipliziert, um den MAE % und den RMSE % zu erhalten.

$$MAE\% = \frac{\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|}{\frac{1}{n} \sum_{i=1}^n y_i} \times 100 \quad (15)$$

$$RMSE\% = \frac{\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}}{\frac{1}{n} \sum_{i=1}^n y_i} \times 100 \quad (16)$$

Auf diese Weise werden die Kennzahlen in prozentualer Relation zum Aktienkurs ausgedrückt, was eine bessere Vergleichbarkeit und Beurteilung der Prognoseverfahren ermöglicht.

5.2 Analyseverfahren für Holt-Winters und ARIMA

Für alle vorgestellten Prognoseverfahren gilt ein zweistufiger Ansatz: Zunächst werden die besten Architekturen und Parametereinstellungen ermittelt, und anschließend erfolgt die Evaluierung der Leistung der Methode mit den besten Einstellungen anhand von Testdaten.

Um die besten Parametereinstellungen für die statistischen Prognosemethoden zu ermitteln, wurde ein Verfahren entwickelt, das verschiedene Aktien und Zeiträume einbezieht. Da die Performance einer Methode nicht anhand einer einzelnen Aktie beurteilt werden kann, wird die Auswertung anhand von fünf Aktien und einem Index durchgeführt. Da die betrachteten Aktien unterschiedliche Strukturen aufweisen, wie z. B. Volatilität, Wertebereiche der Kurse oder Branchen, hofft man, die Leistung über den gesamten Finanzmarkt zu verallgemeinern. Die betrachteten Aktien/Indizes sind Deutsche Post AG, Allianz SE, McDonald's, Amazon, NVIDIA und der MDAX. Ähnliches gilt für die Variation der Zeiträume. Diese Zeiträume beginnen mit einer Prognose ab dem 05.12.2022, 06.02.2023, 04.05.2023 und 26.06.2023, wobei die historischen Kurse bis einen Tag vor den genannten Daten als Trainingsdaten für das Modell dienen. Die Performance des Modells wird dann anhand der Testdaten (10 Tage ab dem Prognosetag) gemessen, indem die tatsächlichen Kurse mit den prognostizierten verglichen werden. Abbildung 9 veranschaulicht diese Datenaufteilung am Beispiel eines Zeitraums (Prognose ab dem 26.06.2023). Da die beiden statistischen Prognoseverfahren eine Einstellung beinhalten, die die optimalen Parameter selbstständig berechnet, wird auf die Unterteilung in ein Validierungsset verzichtet, da die automatische Berechnung dort immer am besten abschneiden würde. Dies muss jedoch nicht unbedingt für das Testset gelten.




Abbildung 9: Beispielhafte Aufteilung in Trainings- und Testdaten (Holt-Winters/ARIMA)

Für jede Aktie und jeden Zeitraum wird der MAE % für den 1., 1.-3., 1.-5. und 1.-10. Prognosetag berechnet. Anschließend wird der Durchschnitt dieser Werte über alle Aktien-Zeiträume-Kombinationen gebildet. Durch Variation bestimmter Parameter (beschrieben in Kapitel 6.1 und 6.1) kann die beste Einstellung mithilfe des beschriebenen Verfahrens ermittelt werden. Als Kennzahl wurde bewusst der MAE % gewählt, da dieser eine greifbare Metrik ist, die Prognosen leicht interpretierbar macht.

Nachdem die beste Einstellung für das Holt-Winters- und ARIMA-Verfahren gefunden wurde, kann im zweiten Schritt mittels desselben Verfahrens der MAE % ermittelt werden, um ihn anschließend mit den anderen Methoden zu vergleichen.

5.3 Analyseverfahren für LSTM-Methoden

Auch die Analyse der LSTM-Methoden unterteilt sich in die Evaluierung geeigneter Architekturen und Parametereinstellungen und die Berechnung der Performance der Methode mit den besten Einstellungen.

Hier werden die historischen Daten aber nun in ein Trainings-, Validierungs- und Testset aufgeteilt. Das Trainingsset umfasst 80 % der historischen Kurse und wird verwendet, um das LSTM-Modell zu trainieren. Die Leistung des trainierten Modells wird anhand der Validierungsdaten (20 %) ausgewertet. Sobald die besten Einstellungen für das LSTM Modell gefunden wurden, wird die Performance mithilfe der Testdaten ermittelt. Abbildung 10 verdeutlicht diese Datenaufteilung anhand eines Beispielzeitraums.




Abbildung 10: Beispielhafte Aufteilung in Trainings-, Validierungs- und Testdaten (LSTM)

Im ersten Schritt werden die beste Architektur und die besten Parametereinstellungen für das LSTM ermittelt. Im Gegensatz zu den statistischen Methoden wurde hier ein anderes Verfahren entwickelt, das sich lediglich am Validierungsset orientiert und nicht am Testset. Es ist zu beachten, dass bei dem LSTM (1. Variante) die Performance auf dem Validierungsset nicht direkt auf das Testset übertragen werden kann, da das LSTM-Modell im Testset als Prognose für bspw. den zweiten Tag den prognostizierten Wert des ersten Tages nutzt, während dies im Trainings- und Validierungsset nicht der Fall ist.

Das Verfahren zur Ermittlung der besten Einstellungen orientiert sich an drei Aktien (Deutsche Post AG, Allianz SE und McDonald's) und einem Zeitraum (wie in Abbildung 10 visualisiert). Für jede Aktie wird der RMSE % im Validierungsset berechnet und dann über alle Aktien gemittelt. Durch Variation der Einstellungen kann dieser Wert verglichen werden, um die beste Einstellung zu finden. Als Kennzahl wurde der RMSE % gewählt, da größere Abweichungen stärker bestraft werden sollen.

Nachdem die besten Einstellungen ermittelt wurden, können die LSTM-Modelle auf das in Kapitel 5.2 vorgestellte Analyseverfahren (mit sechs Aktien/Indexen und vier Zeiträumen) angewendet werden, um die Performance anhand des MAE % zu messen. Dabei bleibt die Aufteilung in ein Trainings-, Validierungs- und Testset bestehen. Das Ergebnis kann dann wiederum zum Vergleich der Prognosemethoden herangezogen werden.

6 Ergebnisse

In diesem Kapitel werden zunächst die Ergebnisse der einzelnen Prognosemethoden dargestellt. Das Ziel ist dabei, die besten Einstellungen für jede Methode zu finden. Anschließend wird in Kapitel 6.4 die Performance der einzelnen Prognosemethoden gegenübergestellt, um das vielversprechendste Prognoseverfahren zu bestimmen. Zusätzlich werden die Methoden mit einer naiven Prognose verglichen, die als Referenz gilt. Dabei handelt es sich um eine einfache Prognose, in der der letzte bekannte Kurs gleichzeitig auch die Prognose für die nächsten Tage darstellt [11]. Die benötigten Kurse der zu betrachteten Aktien/Indizes werden über die yfinance-Bibliothek (Version: 0.2.24) [30] abgerufen, die diese wiederum von Yahoo-Financen [29] bezieht.

6.1 Holt-Winters

Wie bereits in Kapitel 5.2 beschrieben gilt, es zunächst die besten Parametereinstellungen der Holt-Winters-Methode zu ermitteln. Zur Umsetzung des Verfahrens wurde die statsmodels-Bibliothek (Version 0.12.0) [24] verwendet. Durch kleinere vorangegangene Tests wird die Anzahl saisonaler Perioden auf zwölf (monatlich) und die Initialisierungsmethode auf legacy-heuristic festgelegt. Im ersten Schritt werden nun verschiedene Parametereinstellungen der Methode untersucht. Nachdem die beste Einstellung ermittelt wurde, wird der Zeithorizont variiert. Am Ende der Auswertung stehen dann die besten Einstellungen der Methode fest.

Zur Untersuchung der besten Parametereinstellungen ist der Zeithorizont auf drei Jahre fixiert. Variiert werden die Gewichtungsfaktoren $\alpha, \beta, \delta \in [0.1; 0.9]$, die Initialisierung der Niveau- und Trendkomponente und die Einstellung, ob die Saison- und Trendkomponente im Modell berücksichtigt werden soll. Außerdem beinhaltet die statsmodels-Methode eine automatische Berechnung der besten Parametereinstellung. Dabei kommen mehrere verschiedenen Heuristiken zum Einsatz. Zudem kann zwischen dem additiven und multiplikativen Modell gewechselt werden. Da extrem viele Kombinationen möglich sind, wird nur eine bestimmte Anzahl an Parameterkombinationen getestet. Ein Auszug der getesteten Parameterkombinationen ist in Tabelle 1 dargestellt. Dabei sind die nicht genannten Parameter einer Zeile automatisch durch die Methode generiert.

Betrachtet man die Durchschnittswerte, so kann die automatische Generierung der Parameter (Auto, additiv bzw. Auto, multiplikativ) nur durch eine Einstellung (Multipl., $\alpha = 0.3$) geschlagen werden. Allerdings liefert das automatische Modell (Auto, additiv) bei den Prognosen für den 1. und 1.-10. Tag jeweils bessere Ergebnisse im Vergleich zur genannten Variante. Zudem lässt sich das automatische Modell besser auf weitere Zeiträume verallgemeinern. Aus diesen Gründen wurde sich für diese Parametereinstellung entschieden und diese für die weiteren Analysen festgelegt.

Parameter	MAE%				
	1.Tag	1.-3.Tag	1.-5.Tag	1.-10.Tag	Durchschnitt
Auto, additiv	0.9954	1.7954	2.1063	2.7237	1.9052
Auto, multiplikativ	1.0079	1.7867	2.1142	2.8371	1.9365
Auto, keine Saison	1.0779	1.9150	2.2713	2.9321	2.0491
Multipl., $\alpha = 0.2$	1.3412	1.9608	2.3338	3.3183	2.2385
Multipl., $\alpha = 0.3$	1.0283	1.6196	1.9813	2.8658	1.8738
Multipl., $\alpha = 0.3, \beta = 0.3$	1.3225	1.9900	2.3763	3.4500	2.2847
Addit., $\alpha = 0.3, \beta = 0.2$	1.2942	1.9571	2.2788	3.2304	2.1901
Init. Werte, keine Saison	1.0504	1.8604	2.1896	2.7846	1.9713

Tabelle 1: Auszug der Ergebnisse des Parametertunings von Holt-Winters

Im zweiten Schritt wird nun die Auswirkung der Variation des Zeithorizonts auf das Holt-Winters-Modell untersucht. Dieser variiert zwischen 1, 2, 3, 5, 10 und 20 Jahren. Die Ergebnisse sind in Tabelle 2 aufgeführt.

MAE%	Zeitraum historische Daten					
	1 Jahr	2 Jahre	3 Jahre	5 Jahre	10 Jahre	20 Jahre
1. Tag	1.0554	1.0713	0.9954	1.0342	1.0542	1.0529
1.-3.Tag	1.8367	1.8367	1.7954	1.7883	1.8475	1.8554
1.-5. Tag	2.1496	2.1583	2.1063	2.0900	2.1842	2.1708
1.-10. Tag	2.7358	2.7812	2.7237	2.6654	2.8100	2.7821
Durchschnitt	1.9444	1.9619	1.9052	1.8945	1.9740	1.9653

Tabelle 2: Ergebnisse Zeithorizont Holt-Winters

Hier zeigt sich, dass ein Zeithorizont von fünf Jahren das beste Durchschnittsergebnis erzielt. Die Differenz zu drei Jahren ist dabei gering. Die anderen betrachteten Zeiträume weichen jedoch deutlich von diesem Ergebnis ab. Dies lässt sich interpretieren, indem man berücksichtigt, dass das Modell bei einem oder zwei Jahren nicht genügend Daten hat, um Saisonalitäten zu erfassen. Bei einem großen Zeithorizont hingegen werden auch die Jahre erfasst, in denen die Aktienkurse noch weit unter dem aktuellen Stand lagen. Dadurch kann das Modell die Parameter nicht ausreichend gut bestimmen.

Somit wurden die besten Parametereinstellungen (Auto, additiv) und der vielversprechendste Zeithorizont (5 Jahre) für die Holt-Winters-Methode gefunden. Dieses Ergebnis kann später zum Methodenvergleich herangezogen werden. Im Anhang befindet sich eine Visualisierung der tatsächlichen Kurse im Vergleich zu den vom Modell trainierten/angepassten Kursen anhand einer Aktie und einem Zeitraum (Abbildung 17).

In Abbildung 11 ist der Vergleich der Holt-Winters-Prognose mit den tatsächlichen Kursen anhand der McDonald's Aktie dargestellt. Dabei ist zu erkennen, dass die Prognose sehr gleichbleibend mit leichten Auf- und Abstiegen verläuft. Dies ist für die meisten Aktien-Zeitraums-

Kombinationen der Fall, da das Modell die Parameter automatisch so anpasst, dass dem letzten bekannten Kurs die meiste Gewichtung beigemessen wird und durch die geringe Trend- und Saisonkomponente angepasst wird. Dadurch wird der letzte bekannte Kurs nahezu konstant in der Prognose beibehalten. Zudem fällt auf, dass die Prognose für den ersten Tag direkt stark vom tatsächlichen Kurs abweicht. Dies ist darauf zurückzuführen, dass der Kurs am 23.06.2023 bei 267,60 € lag und dann am 26.06.2023 deutlich fiel. Diese Änderung kann das Holt-Winters-Modell mit seinen festgelegten Parametern jedoch nicht vorhersagen. Alles in allem stellt die Holt-Winters-Prognose eher eine verbesserte naive Prognose dar, bei der leichte Trends erkennbar sind.




Abbildung 11: Vergleich Holt-Winters-Prognose zu tatsächlichen Kursen

6.2 ARIMA

Nachdem sich bereits im vorherigen Kapitel die automatische Methode zur Bestimmung der Parameter durchgesetzt hat, wird zur Umsetzung des ARIMA-Verfahrens die AutoArima-Methode der pmdarima-Bibliothek (Version: 2.0.3) [18] verwendet. Diese bestimmt die Parameter p , d und q für jede Aktie automatisch, wodurch das Ermitteln der besten Parametereinstellungen entfällt. Diese bestimmt sie durch eine Gittersuche, in der verschiedene Parameterkombinationen abgelaufen werden und deren Performances anhand einer Metrik verglichen werden. Die im Folgenden beschriebenen Parameter wurden durch vorausgegangene Tests fixiert. Als Optimierer wird bfgs (Broyden-Fletcher-Goldfarb-Shanno) festgelegt. Das Modell führt maximal 20 Durchläufe zur Parameterermittlung durch, und die saisonale Komponente wird auf sechs Monate festgelegt,

was saisonalen Schwankungen im 6-Monats-Takt entspricht.

Analog zum vorherigen Kapitel wird nun die Auswirkung des Zeithorizonts auf die Methode untersucht. Die entsprechenden Ergebnisse sind in Tabelle 3 aufgeführt. Dabei zeigt sich, dass ein Zeithorizont von zwei Jahren das beste Durchschnittsergebnis erzielt, während die anderen Zeithorizonte deutlich davon abweichen.

MAE%	Zeitraum historische Daten					
	1 Jahr	2 Jahre	3 Jahre	5 Jahre	10 Jahre	20 Jahre
1. Tag	1.0433	1.0312	1.0629	1.0667	1.0583	1.0562
1.-3.Tag	1.8383	1.8004	1.8429	1.8471	1.8542	1.8470
1.-5. Tag	2.1804	2.1308	2.1612	2.1654	2.1917	2.1862
1.-10. Tag	2.7983	2.7042	2.7054	2.7225	2.7821	2.7787
Durchschnitt	1.9651	1.9167	1.9431	1.9504	1.9716	1.9670

Tabelle 3: Ergebnisse Zeithorizont ARIMA




Abbildung 12: Vergleich ARIMA-Prognose zu tatsächlichen Kursen

Mit der Fixierung des Zeithorizonts auf zwei Jahre wurden die besten Parametereinstellungen der ARIMA-Methode gefunden und diese Ergebnisse können für den Methodenvergleich genutzt werden. In Abbildung 12 ist der Vergleich der ARIMA-Prognose mit den tatsächlichen Kursen anhand der McDonald's Aktie dargestellt. Auch hier zeigt sich, dass die Prognose einen stabilen Verlauf mit minimalen Änderungen aufweist. Ähnlich wie beim Holt-Winters-Modell wird auch hier der letzte bekannte Kurs beibehalten und leicht verändert. In vielen Fällen errechnet das

Modell eine p , d und q Belegung von 0, 1, 0, was einer naiven Prognose entspricht, da keine AR- und MA-Komponente zum Einsatz kommt, sondern lediglich der letzte bekannte Kurs als Prognose für die Zukunft berücksichtigt wird. Eine solche Belegung der Parameter deutet darauf hin, dass die ARIMA-Methode zur Vorhersage von Aktienkursen nicht gut geeignet ist.

6.3 LSTM

Für die Umsetzung der LSTM-Verfahren wird die TensorFlow-Bibliothek (Version: 2.12.3) [25] verwendet. Bevor auf vorab definierte Parameter und das allgemeine Vorgehen zur Ermittlung der besten Architektur und Parametereinstellungen eingegangen wird, werden Erkenntnisse nach den ersten Tests der Verfahren präsentiert.

Es wurde beobachtet, dass bei wiederholter Durchführung des Verfahrens für dieselbe Aktie mit identischen Einstellungen sowohl die Performance auf dem Trainings- und Validierungsset, als auch die resultierenden Prognosen stark voneinander abweichen. In Tabelle 4a ist die Abweichung der Performance anhand der Tesla Aktie mit dem LSTM Verfahren (1. Variante) dargestellt. So ergab sich bei drei Durchläufen bspw. eine Min-Max-Differenz von 1.3377 auf dem Validierungsset. Obwohl zu erwarten war, dass die trainierten Modelle aufgrund des zufallsgesteuerten Trainings unterschiedlich sein würden, ist die Deutlichkeit dieser Abweichungen überraschend. Dies deutet darauf hin, dass das Modell Schwierigkeiten hat, die Komplexität der Kursdaten angemessen zu erfassen.

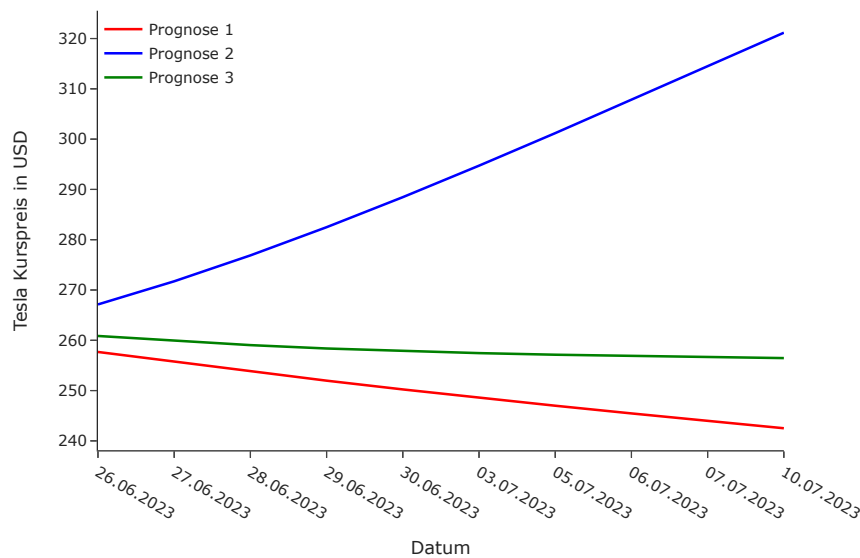


Abbildung 13: Unterschiedliche LSTM-Prognosen

In Abbildung 13 sind, die sich stark unterscheidenden Prognosen visualisiert. Hier lässt sich erkennen, dass selbst der Trend, also ob eine Aktie steigt oder fällt, je Durchlauf variiert. Demnach weisen die LSTM-Verfahren eine geringere Stabilität und Generalisierbarkeit auf.

Da diese stark variierenden Ergebnisse keine zuverlässige Analyse der besten Architektur und Parameter ermöglichen, wurden Lösungsansätze gesucht, die dennoch aussagekräftige Vergleiche ermöglichen. Zum einen wurde ein Callback-Mechanismus implementiert, der das innerhalb der Trainings beste gefundene Modell anhand der Performance auf dem Validierungsset nutzt, anstatt standardmäßig nur das zuletzt trainierte Modell zu verwenden. Zum anderen werden ab sofort zur Berechnung des RMSE % mehrere Durchläufe einer Aktie durchgeführt und aus den Ergebnissen ein Mittelwert gebildet. Nach der Umsetzung dieser beiden Lösungen ergeben sich die in Tabelle 4b dargestellten Ergebnisse. Hier zeigt sich eine deutlich kleinere Min-Max-Differenz. Somit ist eine aussagekräftige Vergleichbarkeit gewährleistet und die verschiedenen Architekturen und Parameter können anhand der Performance auf dem Validierungsset verglichen werden. Jedoch konnte damit das Problem der verschiedenen Prognosen nicht gelöst werden. Auch andere Ansätze, wie bspw. das Erhöhen der Epochen-Anzahl, zeigten nicht die gewünschte Resonanz. Somit bleibt die Erkenntnis bestehen, dass die Prognosen teilweise unberechenbar sind und demnach Vergleiche anhand der Prognosen nahezu unmöglich sind.

Durchlauf	RMSE Train	RMSE Val	Durchlauf	RMSE Train	RMSE Val
1	10.9244	7.4092	1	10.7473	7.4321
2	12.2583	8.7469	2	11.0333	7.6048
3	11.2043	7.8511	3	10.5997	7.3359
Dif. Min-Max	1.3339	1.3377	Dif. Min-Max	0.4336	0.2689

(a) Abweichung: Vorher

(b) Abweichung: Nachher

Tabelle 4: Performance vorher vs. nachher

Des Weiteren fiel auf, dass die Performance auf dem Validierungsset überraschenderweise deutlich besser ist als auf dem Trainingsset, was auf den ersten Blick verwirrend erscheint, da normalerweise das Gegenteil erwartet wird. Durch eine genauere Analyse hat sich herausgestellt, dass im betrachteten Zeitraum (2020-2023) manche Aktien eine bessere Performance auf dem Validierungsset (z. B. McDonald's) als auf dem Trainingsset aufwiesen und andere wiederum nicht (z. B. Amazon). Interessanterweise kehrte sich das Verhältnis um, als der Zeitraum auf 2017 bis 2020 geändert wurde. Sämtliche Aktien zeigten dann eine bessere Performance auf dem Trainingsset als auf dem Validierungsset. Dieses Phänomen lässt sich durch die unterschiedlichen Strukturen innerhalb der beiden Datensätze erklären. Im Zeitraum von 2020 bis 2023 war das Trainieren des Modells aufgrund der starken Kurschwankungen (bspw. aufgrund der Corona-Pandemie) deutlich anspruchsvoller. Eine detaillierte Untersuchung dieser Unterschiede wird in dieser Arbeit jedoch nicht weiter vertieft.

Für die beiden LSTM-Varianten werden die gleichen, nun folgenden Untersuchungen durch-

geführt. Zunächst wird die beste Architektur gesucht. Anschließend erfolgt die Suche nach der optimalen Fenstergröße, gefolgt von der Identifizierung des besten Zeithorizonts. Alle Analysen werden mit dem in Kapitel 5.3 vorgestellten Analyseverfahren zur Bestimmung der RMSE%-Werte durchgeführt. Wie zuvor beschrieben, wird auch hier der Callback-Mechanismus genutzt, und für jede Aktie werden fünf Durchläufe vollzogen. Es sei angemerkt, dass auch komplexere Analysemethoden zur Ermittlung der besten Architektur und Parametereinstellungen, wie bspw. eine Gittersuche, möglich wären. Da jedoch in dieser Arbeit auch andere Methoden entwickelt und analysiert werden, wird bewusst eine weniger komplexe Suchstrategie (wie oben beschrieben) gewählt. Außerdem findet die Normalisierung und Windowing-Technik aus Kapitel 4.3.3 Anwendung.

Wie aus den vorherigen Verfahren bekannt, wurden nach kleineren Tests folgende Parameter für beide LSTM-Varianten festgelegt. So nutzen sie 80 Epochen, eine Chargengröße von 32, den Adam-Optimierer und eine Lernrate von 0.001. Zur Berechnung der Abweichung innerhalb des Modells wird der MSE genutzt und die Relu-Aktivierungsfunktion für die zwischengeschalteten Dense-Layer gewählt.

6.3.1 LSTM (1. Variante)

Im ersten Schritt wird die beste Architektur des LSTM ermittelt. Dazu wird der Zeithorizont auf drei Jahre und die Fenstergröße auf 40 Kurse festgelegt. Es werden verschiedene Architekturen untersucht, wie in Tabelle 5 dargestellt. Dabei werden u.a. mehrere aufeinanderfolgende LSTM-Schichten und ein zwischengeschalteter Dense-Layer (32) genutzt. Zusätzlich wird die Anzahl der Neuronen (N) pro LSTM-Schicht variiert (32, 64 und 128). Unter der Verwendung mehrerer aufeinanderfolgender LSTM-Schichten verspricht man sich einen positiven Effekt auf die Performance des Modells, da durch die Stapelung komplexere Muster und Abhängigkeiten erkannt werden könnten [28]. Ein Dense-Layer besteht aus einer Gruppe von Neuronen, die vollständig mit den Neuronen der vorherigen Schicht verbunden sind. Dieser wird verwendet, um die abstrakten Darstellungen in eine konkrete Vorhersage umzuwandeln.

Die Ergebnisse sind in Tabelle 5 zusammengefasst. Im Allgemeinen zeigt sich, dass eine Erhöhung der Neuronenanzahl kontinuierlich zu einer Verbesserung der Leistung führt. Die daraus resultierende steigende Komplexität führt jedoch zu einer deutlich längeren Trainingszeit des Modells. Des Weiteren wird deutlich, dass die Verwendung einer zusätzlichen LSTM-Schicht bessere Ergebnisse erzielt als bei Verwendung von nur einer einzigen LSTM-Schicht. Allerdings zeigen sich bei Verwendung von drei aufeinanderfolgenden LSTM-Schichten schlechtere Ergebnisse. Die Hinzunahme eines weiteren Dense-Layers hat ebenfalls positive Auswirkungen auf die Performance. Die Reduzierung der Neuronenanzahl pro Schicht führte hingegen nicht zu einer verbesserten Performance im Vergleich zur Variante ohne diese Reduzierung. Unter allen getesteten Architekturen erzielt die Variante mit zwei LSTM-Schichten, jeweils mit 128 Neuronen, und zwei Dense-Layern das beste Ergebnis. Aufgrund der deutlich größeren Laufzeit dieses Modells wird

Architektur	RMSE%		
	32 N	64 N	128 N
LSTM (N), Dense (1)	1.8259	1.7336	1.6841
2× LSTM (N), Dense (1)	1.8046	1.6495	1.5685
3× LSTM (N), Dense (1)	1.8725	1.6423	1.5937
LSTM (N), Dense (32), Dense (1)	1.5692	1.5620	1.5555
2× LSTM (N), Dense (32), Dense (1)	1.7367	1.6238	1.5527
3× LSTM (N), Dense (32), Dense (1)	1.9523	1.6576	1.6053
LSTM (N), LSTM (N/2) Dense (1)	x	1.6662	1.5777
LSTM (N), LSTM (N/2), LSTM (N/4) Dense (1)	x	x	1.5993
LSTM (N), LSTM (N/2), Dense (N/4), Dense(32), Dense (1)	x	1.7073	1.5749
LSTM (N), LSTM (N/2), LSTM (N/4), Dense (32), Dense (1)	x	x	1.6975

Tabelle 5: Ergebnisse der verschiedenen LSTM-Architekturen

jedoch die Variante mit einer LSTM-Schicht mit 64 Neuronen und zwei Dense-Layern für die weiteren Analysen ausgewählt und beibehalten. Diese Variante stellt die drittbeste dar und weist nur geringfügige Abweichungen zur besten Variante auf.

Im zweiten Schritt wird die Fenstergröße variiert, während die Architektur festgehalten und der Zeithorizont weiterhin auf drei Jahre eingestellt wird. Die Ergebnisse dieser Variation sind in Tabelle 6 aufgeführt. Dabei erzielt eine Fenstergröße von 50 Kursen das beste Ergebnis. Wie erwartet erzielen größere Fenstergrößen bessere Ergebnisse als kleinere, da sie eine größere Anzahl von Vergangenheitswerten als Eingabe für die Prognose eines Tages berücksichtigen und dadurch Muster besser erkennen können.

Fenstergr.	1	5	10	20	30	40	50	60	70
RMSE%	1.6253	1.8300	1.6537	1.5928	1.5952	1.5620	1.5058	1.5545	1.5376

Tabelle 6: Ergebnisse der verschiedenen Fenstergrößen (LSTM)

In Tabelle 7 sind die Ergebnisse der Variation des Zeithorizonts unter Fixierung der Architektur (s.o.) und Fenstergröße (50) dargestellt. Dabei zeigt sich ein Horizont von drei Jahren als beste Einstellung. Dieses Ergebnis kann durch die Optimierung der vorherigen Einstellungen, bei denen drei Jahre festgelegt wurden, beeinflusst worden sein. Allerdings zeigte sich auch unabhängig davon ein Zeithorizont von drei Jahren als vielversprechend. Mit zunehmendem Zeithorizont verschlechtern sich die Ergebnisse deutlich, da weitere Kurse mit unterschiedlichen Mustern und globalen Krisen in das Training des Modells einfließen, was die Komplexität erheblich erhöht.

Zeithorizont (in Jahren)	2	3	5	7	10
RMSE%	1.5426	1.5186	1.6340	1.8218	1.6846

Tabelle 7: Ergebnisse Zeithorizont LSTM

Damit wurden die besten Einstellungen für das LSTM-Modell ermittelt. In Abbildung 14 ist der Vergleich der LSTM-Prognose mit den tatsächlichen Kursen anhand der McDonald's Aktie dargestellt. Es wird deutlich, dass das Verfahren einen Trend erkennt und diesen ohne Unterbrechung verfolgt. Dies ist darauf zurückzuführen, dass der prognostizierte Kurs des ersten Tages für die Prognose des zweiten Tages (usw.) verwendet wird. In diesem Beispiel wäre die Vorhersage eines steigenden Trends besser gewesen. Der beschriebene Verlauf ist für alle betrachteten Aktien und Zeiträume nahezu identisch, abgesehen von der Tatsache, dass auch steigende Trends vorhergesagt werden. Im Anhang ist außerdem eine Visualisierung der tatsächlichen Kurse im Vergleich zu den vom Modell prognostizierten Kursen innerhalb des Trainings- und Validierungssets zu finden (Abbildung 18).

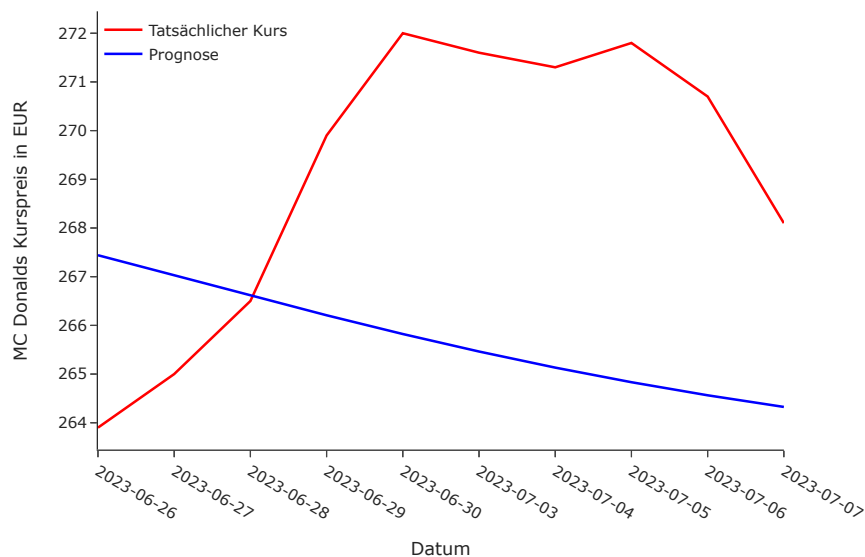


Abbildung 14: Vergleich LSTM-Prognose zu tatsächlichen Kursen

6.3.2 LSTM-One-Shot (2. Variante)

Für das LSTM One-Shot-Modell werden nun die gleichen Untersuchungen wie im vorherigen Abschnitt durchgeführt. Dabei zeigt sich, dass die RMSE%-Werte deutlich größer ausfallen, als bei der ersten Variante. Dies liegt daran, dass die Berechnung des RMSE für das One-Shot-Modell, das immer 10-tägige Prognosen erzeugt, anders verläuft. Hier wird der RMSE für jede 10-tägige Prognose ermittelt, wobei jeder Tag in zehn verschiedenen 10-tägigen Prognosen vorkommt, da das Fenster immer nur um einen Tag und nicht um zehn verschoben wird.

In Tabelle 8 sind die Ergebnisse der Architektur-Untersuchung bei fixierter Fenstergröße (20) und Zeithorizont (3 Jahre) dargestellt. Dabei werden die gleichen Architekturen wie bei der

ersten Variante analysiert. Einzige Ausnahme ist der letzte Dense-Layer, der nun zehn statt einem Neuron enthält, da direkt zehn Tage vorhergesagt werden. Bei den Ergebnissen zeigte sich erneut, dass mehr Neuronen je Schicht auch eine bessere Performance erzielen. Im Gegensatz zum LSTM-Verfahren (1. Variante) führt ein zwischengeschalteter Dense-Layer jedoch nicht zu einer Verbesserung der Ergebnisse. Die Architektur mit zwei LSTM-Schichten, jeweils mit 128 Neuronen, und einem Dense-Layer erweist sich als beste Einstellung und wird für die weiteren Analysen festgehalten.

Architektur	RMSE%		
	32 N	64 N	128 N
LSTM (N), Dense (10)	3.6765	3.4869	3.4356
2× LSTM (N), Dense (10)	3.5218	3.3572	3.2325
3× LSTM (N), Dense (10)	3.6209	3.4209	3.2442
LSTM (N), Dense (32), Dense (10)	3.3762	3.3624	3.3288
2× LSTM (N), Dense (32), Dense (10)	3.6192	3.4090	3.3062
3× LSTM (N), Dense (32), Dense (10)	3.8652	3.4411	3.7118
LSTM (N), LSTM (N/2) Dense (10)	x	3.3982	3.3283
LSTM (N), LSTM (N/2), LSTM (N/4) Dense (10)	x	x	4.6954
LSTM (N), LSTM (N/2), Dense (Ns/4), Dense(32), Dense (10)	x	3.6531	3.2757
LSTM (N), LSTM (N/2), LSTM (N/4), Dense (32), Dense (10)	x	x	3.8750

Tabelle 8: Ergebnisse der verschiedenen LSTM-One-Shot-Architekturen

Die Ergebnisse der Variation der Fenstergröße sind in Tabelle 9 aufgeführt. Hierbei wird die zuvor festgelegte Architektur und ein Zeithorizont von drei Jahren beibehalten. Es zeigt sich, dass eine Fenstergröße von 30 Kursen als die beste Einstellung darstellt. Dabei liegen die ersten drei Fenstergrößen nahe beieinander, während die anderen deutlich davon abweichen.

Fenstergr.	10	20	30	40	50	60	70
RMSE%	3.2862	3.2442	3.1765	3.5123	3.4618	3.4488	6.5452

Tabelle 9: Ergebnisse der verschiedenen Fenstergrößen (LSTM-One-Shot)

In Tabelle 10 sind die Ergebnisse der Variation des Zeithorizonts unter Fixierung der bereits untersuchten Architektur und Fenstergröße dargestellt. Auch hier erweist sich ein Horizont von drei Jahren als beste Einstellung. Die Ergebnisse weisen ähnliche Strukturen wie bei der ersten Variante auf.

Zeithorizont (in Jahren)	2	3	5	7
RMSE%	3.2981	3.2462	4.3239	5.0489

Tabelle 10: Ergebnisse Zeithorizont LSTM-One-Shot

Somit wurden die besten Einstellungen des LSTM-One-Shot-Modells ermittelt und können für

den Methodenvergleich herangezogen werden. In Abbildung 15 ist eine Prognose anhand der McDonald's Aktie dargestellt. Es ist erkennbar, dass die One-Shot-Variante nun auch schwankende Kursprognosen vorhersagt, was einem normalen Kursverlauf entspricht.




Abbildung 15: Vergleich LSTM-One-Shot-Prognose zu tatsächlichen Kursen

6.4 Methodenvergleich

In den nachfolgenden Abschnitten erfolgt ein detaillierter Vergleich der Prognosemethoden sowie weitere Analysen. Zunächst wird in Abschnitt 6.4.1 ein Vergleich der vier analysierten Prognosemethoden, unter Verwendung ihrer jeweils besten Einstellungen, präsentiert. Anschließend wird die Holt-Winters-Methode und das LSTM-Verfahren (Variante 1) einander gegenüber gestellt, indem sie anhand einer spezifischen Kurssituation evaluiert werden. Zum Abschluss dieses Kapitels wird eine vergleichende Untersuchung der beiden LSTM-Verfahren hinsichtlich ihrer Prognosegenauigkeit auf einem Testset über einen Zeitraum von 30 Tagen durchgeführt.

6.4.1 Vergleich der Prognoseverfahren

Nachdem die besten Einstellungen für alle Prognosemethoden ermittelt wurden, erfolgt ein Vergleich dieser miteinander. Zu diesem Zweck wird das in Kapitel 5 vorgestellte Analyseverfahren verwendet, um die MAE%-Werte für die vier Prognosemethoden zu bestimmen. Die Ergebnisse sind in Tabelle 11 dargestellt. Zusätzlich wird die naive Prognose, als simpelstes Prognoseverfahren, als Referenz aufgeführt.

MAE%	Naiv	Holt-Winters	ARIMA	LSTM	LSTM OS
1. Tag	1.0392	1.0342	1.0312	0.9975	1.6217
1.-3. Tag	1.8279	1.7883	1.8004	1.6158	1.7921
1.-5. Tag	2.1388	2.0900	2.1308	2.0046	2.0850
1.-10. Tag	2.7196	2.6654	2.7042	2.7946	2.7717
Durchschnitt	1.9314	1.8945	1.9167	1.8531	2.0676

Tabelle 11: Prognosegüte der verschiedenen Methoden im Vergleich

Die Ergebnisse zeigen, dass die LSTM-Methode (1. Variante) sowohl im Durchschnitt als auch in den meisten Einzelkategorien die besten Ergebnisse erzielt. Da das Modell explizit darauf trainiert ist, genau einen Tag zu prognostizieren, weist es auch die beste Abweichung für den ersten Tag auf. Auch bis zum fünften Tag erzielt sie die besten Ergebnisse. Lediglich bei der 1.-10. Tagesspanne muss sie sich den statistischen Verfahren und der naiven Prognose geschlagen geben, da hier die letzten Werte stärker vom tatsächlichen Kurs abweichen. Zudem zeigt sich bei einem Vergleich der beiden statistischen Verfahren, dass die Holt-Winters-Methode die bessere Leistung aufweist.

Das One-Shot-Modell ist das einzige Verfahren, das keinen besseren Durchschnittswert als die naive Prognose aufweist. Insbesondere am ersten Tag ist die Abweichung extrem hoch. Dies liegt daran, dass das Modell speziell für eine 10-Tage-Prognose trainiert wird. Dementsprechend zeigt es im 10-Tage-Zeitraum eine bessere Performance als das andere LSTM-Modell. Eine detaillierte Gegenüberstellung der beiden LSTM-Verfahren erfolgt in Kapitel 6.4.3.

Allerdings hat das bereits beschriebene Problem der unterschiedlichen Prognosen auch hier Auswirkungen auf die Ergebnisse der LSTM-Verfahren. So werden bei wiederholter Ausführung der ersten Variante unterschiedliche Ergebnisse erzeugt. Der Durchschnitt über alle Zeitspannen (letzte Zeile) variiert nach zehn Durchläufen zwischen 1.8288 und 1.9254. Somit erzielt das LSTM-Verfahren je nach Durchlauf ein besseres oder schlechteres Ergebnis als die Holt-Winters-Methode. Es zeigt sich erneut, dass eine Vergleichbarkeit der LSTM-Verfahren mit den anderen Methoden aufgrund der instabilen Ergebnisse nicht möglich ist. Das Mitteln der zehn Durchschnittswerte ergibt jedoch einen Wert von 1.88, was weiterhin besser ist als die Holt-Winters-Methode. Im Schnitt bleibt also die Erkenntnis bestehen, dass das LSTM-Verfahren die besten Ergebnisse erzielt. Dennoch kann aufgrund der instabilen Ergebnisse der LSTM-Methoden kein eindeutiger Sieger ermittelt werden. Eine Prognose basierend auf einem einzelnen LSTM-Durchlauf sollte daher mit äußerster Vorsicht betrachtet werden. Das mehrmalige Durchführen des Verfahrens und anschließendes Mitteln der prognostizierten Kurse ist aber einerseits unpraktisch und spricht andererseits gegen die Methode selbst.

Generell wäre eine größere Abweichung der Ergebnisse der betrachteten Verfahren im Vergleich zur naiven Prognose zu erwarten gewesen, da diese die einfachste aller Prognosemethoden darstellt. Es scheint jedoch, dass sich positive und negative Ausschläge der Kurse gegenseitig neu-

tralisieren und daher eine konstante Kursprognose gut abschneidet.

Abschließend soll dem MAE%-Wert noch eine greifbare Interpretation gegeben werden. Betrachtet man bspw. das Ergebnis für die LSTM-Methode aus Tabelle 11 und eine Aktie mit einem durchschnittlichen Kurs von 200 €, so beträgt die Abweichung am ersten Tag im Schnitt $\frac{0.9975 \cdot 200}{100} = 2$ €. Die Holt-Winters-Prognose erzielt eine Abweichung von 2.07 €. Für den 1.-10. Tag beträgt die durchschnittliche Abweichung 5.59 € (LSTM) und 5,33 € (Holt-Winters). Die Abweichungen der verschiedenen Verfahren liegen im Euro-Wertebereich demnach nah beieinander. Außerdem kann eine Abweichung um wenige Euro im betrachteten Prognosezeitraum als solide interpretiert werden.

6.4.2 Holt-Winters vs. LSTM (1. Variante)

Aus vorherigem Abschnitt wurde bereits deutlich, dass das LSTM hinsichtlich seiner Prognosegenauigkeit dem Holt-Winters-Modell überlegen sein kann. Um die Vorzüge des LSTM-Verfahrens und die Einschränkungen des Holt-Winters-Verfahrens darzustellen, wurde eine Analyse anhand einer Aktie (Uniper SE) durchgeführt, die im betrachteten Prognosezeitraum von zehn Tagen (ab dem 24.05.2023) eine erhebliche Kurssteigerung aufweist.

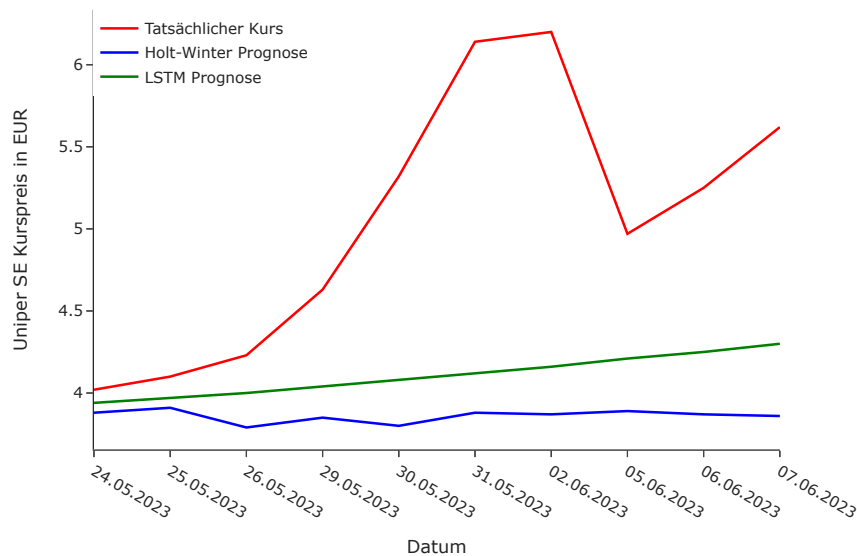


Abbildung 16: Vergleich Prognose Holt-Winters vs. LSTM

In Abbildung 16 ist der stark steigende Kurs und die Prognosen der beiden Verfahren visualisiert. Es ist erkennbar, dass sowohl das Holt-Winters-Modell als auch das LSTM-Modell den starken Kursanstieg nicht vorhersagen können. Die Prognose des Holt-Winters-Verfahrens verläuft, wie

bereits in Kapitel 6.1 erläutert, sehr stabil. Im Gegensatz dazu erkennt das LSTM-Verfahren den aufsteigenden Trend, wenn auch nicht im genauen Ausmaß. Anhand dieses Beispiels wird deutlich, dass das LSTM-Verfahren im Vergleich zur Holt-Winters-Methode eine bessere Performance bei stark schwankenden Aktien aufweist, da es Trends erkennen kann, wenn auch nicht in ihrem tatsächlichen Ausmaß. Bei einem eher stabilen Kursverlauf wäre das Holt-Winters-Verfahren hingegen vorzuziehen.

6.4.3 LSTM vs. LSTM-One-Shot

In diesem Abschnitt werden die beiden LSTM-Verfahren über einen Prognosezeitraum von 30 Tagen miteinander verglichen. Als Grundlage für die Analyse wurde die Aktie der Deutschen Post AG verwendet und die Prognose startet ab dem 02.05.2023. Um eine bessere Vergleichbarkeit der Prognosegenauigkeit zu gewährleisten, wurden für jedes Verfahren zehn Durchläufe durchgeführt und die Ergebnisse gemittelt. Für das LSTM-One-Shot-Verfahren (LSTM OS) wurden drei verschiedene Modelle trainiert, die 10-, 20- und 30-Tage-Prognosen erstellen. Dabei wurden für alle Modelle dieselben besten Einstellungen, wie in Abschnitt 6.3.2 beschrieben, verwendet. Die Ergebnisse sind anhand der MAE%-Werte der Verfahren in Tabelle 12 aufgeführt.

MAE %	LSTM OS			LSTM
	10d Prognose	20d Prognose	30dPrognose	30d Prgonosen
1.Tag	0.693	0.819	1.49	0.641
1.-10. Tag	3.165	3.496	3.389	3.546
1.-20. Tag	x	4.75	4.689	4.768
1.-30. Tag	x	x	4.852	5.161

Tabelle 12: Vergleich 30-Tage-Prognose der LSTM-Modelle anhand der Deutschen Post AG

Zunächst fällt auf, dass bei beiden Methoden die Abweichung zwischen dem prognostizierten und dem tatsächlichen Kurs mit zunehmendem Prognosezeitraum deutlich ansteigt. Demnach sollten diese Verfahren nicht für einen längeren Zeithorizont angewendet werden. Des Weiteren fällt auf, dass die Abweichung am ersten Tag zwischen dem 10-Tage-Modell bis zum 30-Tage-Modell stark zunimmt. Dies ist darauf zurückzuführen, dass die Modelle versuchen, den gesamten Prognosezeitraum zu optimieren. Bei der 10-Tage-Prognose ist dieser Zeitraum jedoch deutlich kürzer, wodurch der erste Tag davon profitiert. Das LSTM (1. Variante) erzielt allerdings die beste Prognose für den ersten Tag, da es ausschließlich auf eine einzige Prognose trainiert wurde. Dementsprechend wird die 1. Variante im 10-Tage Zeitraum vom 10-Tage-LSTM-One-Shot-Modell geschlagen. Gleiches gilt für die anderen beiden Zeiträume. Somit lässt sich festhalten, dass das Modell, welches spezifisch für einen Prognosezeitraum trainiert wurde, auch die besten Ergebnisse in diesem Zeitraum erzielt. Dieser Zusammenhang wird ebenfalls in Tabelle 11 deutlich.

7 Dashboard

Zur Visualisierung der durchgeführten Analysen und Prognoseverfahren wurde ein Finanz-Board mit Plotly Dash [17] entwickelt. Dieses nutzt HTML- und Dash-Core-Komponenten. Außerdem wurde die Dash-Bootstrap-Methode verwendet, die eine Seite in mehrere Zeilen und eine Zeile wiederum in mehrere Spalten unterteilt. Eine Zeile hat dabei eine maximale Breite von 12 Einheiten. Dadurch entsteht eine flexible Gitternetzstruktur, die es ermöglicht, das Dashboard an verschiedene Bildschirmgrößen anzupassen, einschließlich der Nutzung auf Mobilgeräten. Die Elemente sind in sogenannten Cards (Karten) zusammengefasst, um eine einheitliche und kompakte Darstellung zu gewährleisten. Das Dashboard kann nach aktueller Implementierung lokal auf dem Rechner genutzt werden, auf dem auch die Anwendung ausgeführt wird.

Der Aufbau des Finanz-Boards wird im folgenden schriftlich dargestellt. Im Anhang sind ausgewählte Elemente des Boards mittels Bildschirmaufnahmen aufgeführt (Abbildungen 19-24). Das Dashboard besteht aus sechs verschiedene Seiten (Overview, Analyse und vier Seiten für die verschiedenen Prognoseverfahren). Direkt unter der Überschrift des Boards befindet sich eine Leiste, in der zwischen den verschiedenen Seiten gewechselt werden kann. Weiter rechts in der Leiste ist ein Eingabefeld, in das der Nutzer den amerikanischen Token (Schlüssel) einer Aktie eintippen kann, implementiert. Dies ist von allen Seiten aus möglich und aktualisiert die Elemente der Seiten zu der neuen Aktie. Dazu werden die historischen Daten der Aktie heruntergeladen und in einem unsichtbaren Speicher aufbewahrt. Die Elemente der Seite greifen auf diesen zu und aktualisieren sich. Auf der Startseite (Overview) des Dashboards werden dem Nutzer aktuelle Informationen über die ausgewählte Aktie wie Firmensitz, Währung und Geschäftszweig präsentiert. Zudem wird eine Visualisierung aller verfügbaren Kursdaten der Aktie angezeigt. Auf der Analyse-Seite hat der Anwender die Möglichkeit einen Zeitraum der Kursdaten einzustellen. Dabei kann entweder ein Schieberegler mit festen Zeiträumen oder ein Kalender für eine manuelle Zeitraumangabe genutzt werden. Der ausgewählte Zeitraum beeinflusst die Elemente auf dieser Seite, sodass diese sich lediglich auf den gewählten Zeitraum beziehen. Einzige Ausnahme bildet die today-Karte, die tagesaktuelle Informationen wie Kursänderung zu gestern oder Tageshöchstwert bereitstellt. Die zeitraumbezogenen Elemente umfassen eine Visualisierung, eine Tabelle der historischen Daten und eine Informationskarte. In der Visualisierung kann zwischen verschiedenen Kursobjekten, wie Schluss- oder Öffnungskurs, und dem Volumen gewechselt werden. Diese Auswahl beeinflusst die angezeigten statistischen Merkmale (bspw. der Durchschnittspreis) in der Informationskarte. Die folgenden Seiten repräsentieren die verschiedenen Prognoseverfahren aus Kapitel 4. Dabei bildet jedes Verfahren eine eigene Seite, welche sich vom Aufbau und ihrer Funktionalität nicht wesentlich unterscheiden. Der Fokus liegt hier auf der Vorhersage zukünftiger Kurse. Deshalb kann der Anwender zuerst innerhalb eines Dropdown-Menüs wählen, wie viele Tage vom heutigen in die Zukunft prognostiziert werden sollen. Ausgehend davon wird ihm eine Visualisierung der vergangenen 60 Kurse und die prognostizierten Kurse angezeigt. Daneben ist eine Tabelle zu finden, in der die vorhergesagten Kurse mit Datum

dargestellt sind. Darunter befindet sich eine Visualisierung, dass die tatsächlichen, vergangenen Kurse mit den vom Modell vorhergesagten (bzw. angepassten; bei Holt-Winters und ARIMA) Kursen vergleicht. Daneben werden verschiedene Metriken, die die Performance des Modells bewerten, abgebildet. Am Schluss der jeweiligen Prognoseseite kann der Nutzer einen vergangenen Tag mittels eines Kalenders bestimmen, ab dem zehn Tage prognostiziert werden. Da für diesen Zeitraum bereits die tatsächlichen Kursdaten vorliegen, kann das Ergebnis mittels Kennzahlen bewertet werden. Dies wird in einer weiteren Grafik und einer Performance-Karte visualisiert.

Es sei angemerkt, dass bei allen Verfahren (außer Holt-Winters) einfachere, als in den Ergebnissen 6 vorgestellt, Modelle implementiert wurden, um die Ladezeit zu verkürzen. Für die beiden LSTM-Verfahren wurden bereits Modelle für die Tesla und NVIDIA Aktie vortrainiert (Datengrundlage bis zum 23.06.2023). Diese werden bei der Auswahl einer dieser Aktien geladen und nicht neu trainiert.

8 Fazit und Ausblick

Das Ziel dieser Ausarbeitung bestand darin, bewährte Prognoseverfahren für Zeitreihen anhand von Aktienkursen zu bewerten. Zu diesem Zweck wurden vier verschiedenen Verfahren hinsichtlich ihrer Architektur und Parameter verbessert und miteinander verglichen. Es ist aber hervorzuheben, dass keines der betrachteten Verfahren für eine exakte Kursprognose geeignet ist. Die generierten Prognosen dienen lediglich als Richtwert und können nicht für spekulative Zwecke verwendet werden. Gerade über einen längeren Prognosezeitraum nimmt die Performance stark ab. Die LSTM-Methode (1. Variante) erwies sich in den durchgeführten Tests als beste Methode. Allerdings sollte diese Aussage relativiert werden, da bei wiederholter Durchführung der Methode mit exakt gleichen Einstellungen unterschiedliche Ergebnisse erzielt werden. Diese sind dann mal besser oder schlechter als die zweitbeste Methode (Holt-Winters). Dieser Umstand erschwert die Vergleichbarkeit der LSTM-Methoden mit den statistischen Verfahren. Generell lässt sich jedoch festhalten, dass die statistischen Methoden bei sehr stabilen Aktien besser abschneiden, während die LSTM-Verfahren bei stark schwankenden Aktien aufgrund ihrer Fähigkeit, Trends besser umzusetzen, überlegen sind.

Es ist besonders wichtig, sich mit dem Umstand, dass gleiche Einstellungen unterschiedliche Prognosen liefern können, in zukünftigen Untersuchungen auseinanderzusetzen und gegebenenfalls Lösungsansätze zu finden, um eine bessere Vergleichbarkeit zwischen den Methoden zu gewährleisten. Dennoch zeigen maschinelle Lernalgorithmen im Vergleich zu statistischen Methoden vielversprechende Ergebnisse und werden voraussichtlich durch weitere Betrachtungen und den aktuellen Hype um NN sogar bessere Leistungen erzielen. Hierbei ist natürlich auch die Nutzung anderer maschineller Lernmethoden als NN, wie z. B. Support Vector Machines möglich und sinnvoll. Möglicherweise sollte der Fokus zudem von der exakten Kursvorhersage hin zur Vorhersage von Trends (steigender oder fallender Kurs) verlagert werden, da diese

Aufgabenstellung eine geringere Komplexität aufweist. Des Weiteren könnten anstelle von Kursdaten andere statistische Kennzahlen als Eingabe verwendet werden, die die Kursentwicklung beschreiben. Außerdem gibt es weitere spannende Forschungsfelder, die politische, soziale und sonstige Ereignisse in die Prognose einbeziehen. So beschäftigt sich die Event-Study (Ereignisstudie) mit den Auswirkungen eines bestimmten Ereignisses auf den Aktienkurs eines Unternehmens oder Marktes. Dabei werden statistische Methoden verwendet, um den kausalen Bezug zwischen Ereignis und Kursveränderung zu analysieren und zu verstehen. Ein weiterer Zweig ist die Sentimentanalyse, bei der Meinungen oder Stimmungen, die in Nachrichten, sozialen Medien oder anderen Quellen zu bestimmten Unternehmen oder Märkten geäußert werden, automatisch analysiert und zur Kursprognose genutzt werden. Gerade solche Ereignisse und ihre Auswirkungen können mit klassischen NN (wie LSTM) nicht vorhergesagt werden, da ihnen die Informationen fehlen.

Literatur

- [1] BOX, G. E. P., JENKINS, G. M., REINSEL, G. C., AND LJUNG, G. M. *Time series analysis: forecasting and control*. John Wiley & Sons, 2015.
- [2] CHOLLET, F. *Deep Learning mit Python und Keras: Das Praxis-Handbuch vom Entwickler der Keras-Bibliothek*. MITP-Verlags GmbH & Co. KG, 2018.
- [3] DÖHRN, R. *Konjunkturdiagnose und -prognose: Eine anwendungsorientierte Einführung*. Springer-Verlag, 2014.
- [4] ERTEL, W., AND BLACK, N. T. *Grundkurs Künstliche Intelligenz*, vol. 4. Springer, 2016.
- [5] GELPER, S., FRIED, R., AND CROUX, C. Robust forecasting with exponential and holt-winters smoothing. *Journal of forecasting* 29, 3 (2010), 285–300.
- [6] HU, Z., ZHAO, Y., AND KHUSHI, M. A survey of forex and stock price prediction using deep learning. *Applied System Innovation* 4, 1 (2021), 9.
- [7] HU, Z., ZHU, J., AND TSE, K. Stocks market prediction using support vector machine. In *2013 6th International Conference on Information Management, Innovation Management and Industrial Engineering* (2013), vol. 2, IEEE, pp. 115–118.
- [8] KARUNASINGHA, D. S. K. Root mean square error or mean absolute error? use their ratio as well. *Information Sciences* 585 (2022), 609–629.
- [9] KHARE, K., DAREKAR, O., GUPTA, P., AND ATTAR, V. Z. Short term stock price prediction using deep learning. In *2017 2nd IEEE international conference on recent trends in electronics, information & communication technology (RTEICT)* (2017), IEEE, pp. 482–486.
- [10] KOTU, V., AND DESHPANDE, B. *Data science: concepts and practice*. Morgan Kaufmann, 2018.
- [11] KÜHNAPFEL, J. B. *Vertriebsprognosen: Methoden für die Praxis*. Springer, 2015.
- [12] LEINER, B. *Grundlagen der Zeitreihenanalyse*. Oldenbourg Wissenschaftsverlag, 2018.
- [13] LIPTON, Z. C., BERKOWITZ, J., AND ELKAN, C. A critical review of recurrent neural networks for sequence learning. *arXiv preprint arXiv:1506.00019* (2015).
- [14] MANASWI, N. K., AND JOHN, S. *Deep learning with applications using python*. Springer, 2018.
- [15] MÜLLER, J. *Wirtschaft und Finanzmärkte*. Oldenbourg Wissenschaftsverlag, 2018.
- [16] NEUSSER, K., AND WAGNER, M. *Zeitreihenanalyse in den Wirtschaftswissenschaften: Einführung und Grundlagen für den Einstieg in die aktuelle Forschung*. Springer, 2022.

- [17] PLOTLY. Dash Documentation & User Guide. <https://dash.plotly.com/>. Zugriffsdatum: 21.07.2023.
- [18] PMDARIMA. pmdarima. <https://pypi.org/project/pmdarima/>. Zugriffsdatum: 21.07.2023.
- [19] RAHMAN, M. H., SALMA, U., HOSSAIN, M. M., AND KHAN, M. T. F. Revenue forecasting using holt–winters exponential smoothing. *Research & Reviews: Journal of Statistics* 5, 3 (2016), 19–25.
- [20] SHAH, D., ISAH, H., AND ZULKERNINE, F. Stock market analysis: A review and taxonomy of prediction techniques. *International Journal of Financial Studies* 7, 2 (2019), 26.
- [21] SMAGULOVA, K., AND JAMES, A. P. A survey on lstm memristive neural network architectures and applications. *The European Physical Journal Special Topics* 228, 10 (2019), 2313–2324.
- [22] SONI, P., TEWARI, Y., AND KRISHNAN, D. Machine learning approaches in stock price prediction: A systematic review. In *Journal of Physics: Conference Series* (2022), vol. 2161, IOP Publishing, p. 012065.
- [23] STATSMODELS. Stationarity and detrending (ADF/KPSS). https://www.statsmodels.org/dev/examples/notebooks/generated/stationarity_detrending_adf_kpss.html#KPSS-test. Zugriffsdatum: 30.06.2023.
- [24] STATSMODELS. statsmodels 0.14.0. <https://www.statsmodels.org/stable/index.html>. Zugriffsdatum: 21.07.2023.
- [25] TENSORFLOW. TensorFlow. <https://www.tensorflow.org/>. Zugriffsdatum: 21.07.2023.
- [26] TRULL, O., GARCÍA-DÍAZ, J. C., AND TRONCOSO, A. Initialization methods for multiple seasonal holt–winters forecasting models. *Mathematics* 8, 2 (2020), 268.
- [27] VOGEL, J. *Prognose von Zeitreihen*. Springer, 2015.
- [28] YADAV, A., JHA, C., AND SHARAN, A. Optimizing lstm for time series prediction in indian stock market. *Procedia Computer Science* 167 (2020), 2091–2100.
- [29] YAHOOFINANZEN. Yahoo Finanzen - Börse live, Kurse, Nachrichten aus Wirtschafts- und Geschäftswelt. <https://de.finance.yahoo.com/>. Zugriffsdatum: 21.07.2023.
- [30] YFINANCE. yfinance. <https://pypi.org/project/yfinance/>. Zugriffsdatum: 21.07.2023.

Anhang




Abbildung 17: Vergleich tatsächliche zu angepasste Daten (Holt-Winters)




Abbildung 18: Vergleich tatsächliche zu prognostizierte Daten (LSTM)

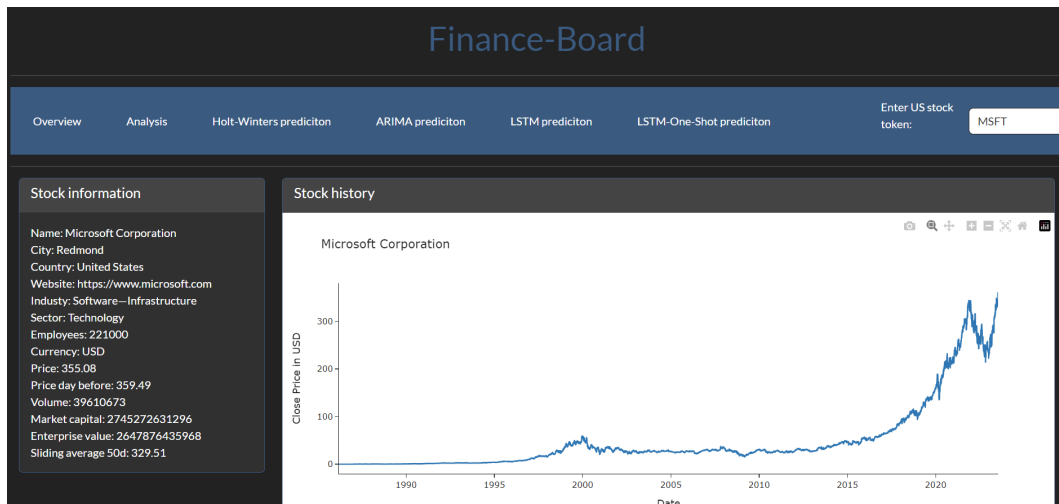


Abbildung 19: Übersicht-Seite Dashboard

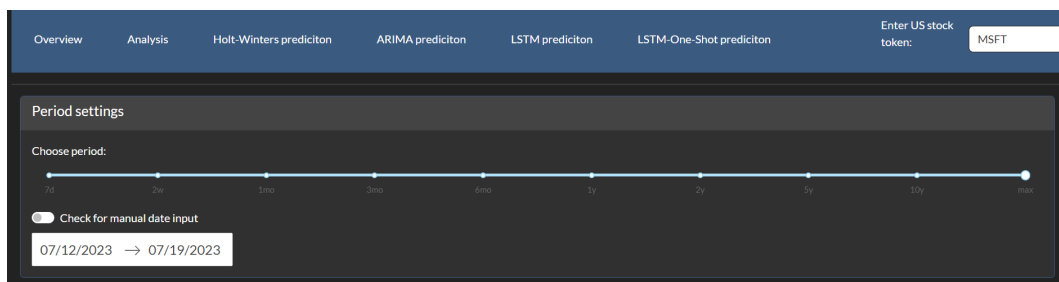


Abbildung 20: Analyse-Seite 1/2

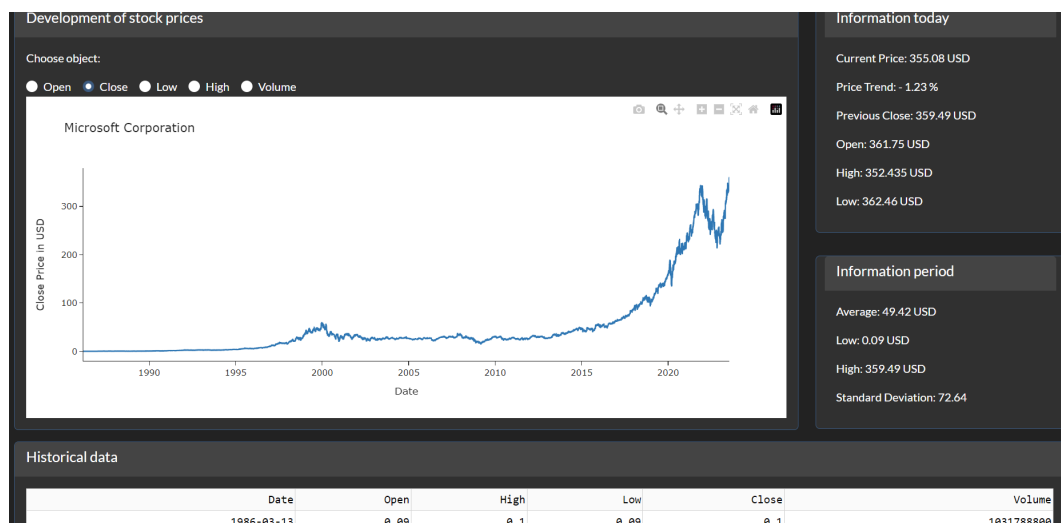


Abbildung 21: Analyse-Seite 2/2

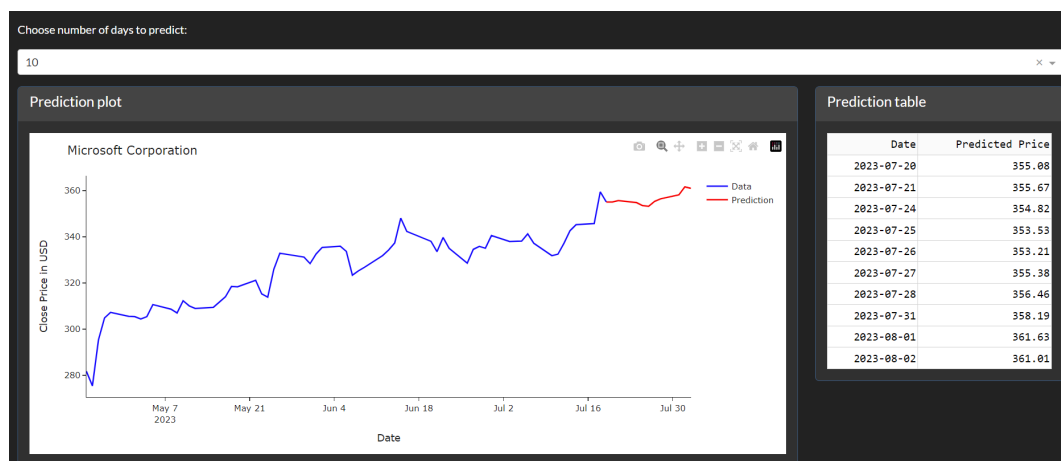


Abbildung 22: Prognose-Seite 1/3



Abbildung 23: Prognose-Seite 2/3



Abbildung 24: Prognose-Seite 3/3